ĐẠI HỌC QUỐC GIA TP.HCM
TRƯỜNG ĐẠI HỌC KINH TẾ - LUẬT
KHOA TOÁN KINH TẾ

# TIỂU LUẬN CUỐI KÌ

Môn: Giới thiệu về học máy
(Lớp 252BMA400601)

# ỨNG DỤNG THUẬT TOÁN HỌC MÁY TRONG DỰ BÁO RỦI RO RỜI BỎ KHÁCH HÀNG THẺ TÍN DỤNG: THỰC NGHIỆM TỪ MÔ HÌNH RANDOM FOREST VÀ PCA

Giảng viên hướng dẫn: Th.S Trương Quang Nhật
Sinh viên thực hiện: Cao Thiên Quang
MSSV: K244191981

# MỤC LỤC

PHẦN MỞ ĐẦU ..... 3
1.1. Tính cấp thiết của đề tài ..... 3
1.2. Ý nghĩa khoa học và thực tiễn ..... 3
1.3. Mục tiêu nghiên cứu ..... 4
1.4. Yêu cầu nghiên cứu ..... 4
1.5. Hạn chế của đề tài và hướng phát triển nghiên cứu ..... 5
PHẦN NỘI DUNG ..... 7
2.1. CƠ SỞ LÝ THUYẾT ..... 7
2.1.1 Tổng quan về Học Thống kê (Statistical Learning) ..... 7
2.1.2 Học không giám sát (Unsupervised Learning) ..... 7
2.1.3 Các mô hình dự báo (Supervised Learning) ..... 8
2.1.4. Đánh giá hiệu năng mô hình (Model Evaluation) ..... 13
2.2. NỘI DUNG NGHIÊN CỨU VÀ PHƯƠNG PHÁP NGHIÊN CỨU ..... 14
2.2.1. Nội dung nghiên cứu ..... 14
2.2.2. Phương pháp nghiên cứu ..... 15
2.3. GIỚI THIỆU VÀ XỬ LÝ DỮ LIỆU ..... 17
2.3.1. Giới thiệu dữ liệu: ..... 17
2.3.2. Thu nhập tiền xử lý dữ liệu: ..... 20
2.4. KỸ THUẬT ĐẶC TRƯNG (FEATURE ENGINEERING) ..... 21
2.4.1. Xây dựng biến mới ..... 21
2.4.2. CHUẨN HÓA DỮ LIỆU ..... 22
2.4.3. MÃ HÓA BIẾN ĐỊNH TÍNH (CATEGORICAL ENCODING) ..... 23
2.5. QUY TRÌNH TINH LỌC DỮ LIỆU VÀ GIẢM CHIỀU (DIMENSIONALITY REDUCTION) ..... 25
2.5.1. Thực nghiệm giảm chiều dữ liệu và tinh chỉnh mô hình PCA: ..... 25
2.6. HUẤN LUYỆN MÔ HÌNH (MODEL TRAINING) ..... 29
2.6.1. Mô hình hồi quy Logistic (Logistic Regression) ..... 29

2.6.2. Random forest và cross-validation ..... 34
2.7. ĐÁNH GIÁ VÀ SO SÁNH ..... 36
2.7.1. Thang đo hiệu năng và Ma trận nhầm lẫn (Confusion Matrix) ..... 36
2.7.2. Đường cong ROC của mô hình dự báo ..... 38
2.7.3. Đối chiếu tính nhất quán giữa K-Means và Random Forest ..... 39
KẾT LUẬN VÀ GIẢI PHÁP QUẢN TRỊ ..... 40
3.1. Lựa chọn mô hình tối ưu cho ngân hàng ..... 40
3.2. Đề xuất chính sách và giải pháp giữ chân khách hàng rủi ro ..... 40
3.3. Kết luận chung ..... 41

# PHẦN MỞ ĐẦU

## 1.1. Tính cấp thiết của đề tài

Trong kỷ nguyên kinh tế số, thẻ tín dụng đã trở thành công cụ thanh toán thiết yếu và là nguồn thu nhập quan trọng của các ngân hàng bán lẻ. Tuy nhiên, sự phát triển mạnh mẽ của hệ thống tài chính cũng kéo theo sự cạnh tranh gay gắt. Một thách thức lớn mà các ngân hàng đang phải đối mặt là Sự rời bỏ của khách hàng. Theo các nghiên cứu kinh tế, chi phí để thu hút một khách hàng mới thường cao gấp 5 đến 25 lần so với việc giữ chân một khách hàng hiện hữu[1]. Do đó, khả năng nhận diện sớm những khách hàng có nguy cơ rời bỏ để đưa ra các biện pháp ứng phó kịp thời là yếu tố then chốt để duy trì lợi thế cạnh tranh.

Thực tế tại các ngân hàng cho thấy, hành vi khách hàng mang tính chất phi tuyến tính và phức tạp cao. Các phương pháp thống kê truyền thống như hồi quy tuyến tính OLS thường bộc lộ hạn chế khi xử lý các dữ liệu nhị phân thưa thớt, dẫn đến khả năng giải thích thấp (thực nghiệm cho thấy hệ số $R^2$ chỉ đạt 0.00026). Chính vì vậy, việc ứng dụng các thuật toán Học máy (Machine Learning) có khả năng tự học các mẫu hình hành vi từ dữ liệu lớn là yêu cầu cấp thiết để tối ưu hóa quy trình quản trị rủi ro khách hàng.

## 1.2. Ý nghĩa khoa học và thực tiễn

Về ý nghĩa khoa học, đề tài vận dụng hệ sinh thái các phương pháp học máy từ cơ bản đến nâng cao. Nghiên cứu thể hiện sự kết hợp chặt chẽ giữa học không giám sát (K-Means Clustering) để phân loại nhóm hành vi, kỹ thuật giảm chiều dữ liệu (PCA) để xử lý đa cộng tuyến, và học có giám sát (Random Forest) để dự báo. Việc đối chiếu giữa các mô hình giúp làm sáng tỏ ưu điểm của phương pháp học kết hợp (Ensemble Learning) so với các mô hình tuyến tính cổ điển trong phân tích dữ liệu tài chính.

Về ý nghĩa thực tiễn, việc ứng dụng mô hình dự báo rủi ro rời bỏ mang lại giá trị tài chính trực tiếp cho ngân hàng. Theo nghiên cứu của Harvard Business Review (Gallo, 2014), chi phí để thu hút một khách hàng mới thường cao gấp 5 đến 25 lần so với việc giữ chân một khách hàng hiện hữu. Đồng thời, nghiên cứu từ Bain & Company (Reichheld, 1990) cũng chỉ ra rằng chỉ cần tăng tỷ lệ giữ chân khách hàng thêm 5%, lợi nhuận của doanh nghiệp có thể tăng trưởng từ 25% đến 95%.

Trong bối cảnh đó, ý nghĩa thực tiễn của nghiên cứu này đối với ngân hàng được thể hiện qua các khía cạnh:

- Thay vì triển khai các chương trình ưu đãi đại trà gây lãng phí nguồn lực, mô hình Random Forest

[1] *"The Value of Keeping the Right Customers"* (2014)

với độ chính xác cao cho phép ngân hàng thực hiện chiến lược 'đánh trúng đích'. Ngân hàng chỉ cần tập trung ngân sách chăm sóc vào nhóm khách hàng thực sự có nguy cơ rời bỏ (thông qua thuật toán K-Means), từ đó giảm thiểu chi phí tiếp thị nhưng vẫn đạt được hiệu quả giữ chân cao nhất.

- Kết quả nghiên cứu cung cấp các ngưỡng hành vi cụ thể (ví dụ: sự sụt giảm tần suất giao dịch tại biến Total_Trans_Ct). Điều này giúp bộ phận quản trị rủi ro chuyển dịch từ thế bị động sang chủ động: can thiệp ngay khi khách hàng có dấu hiệu 'ngủ đông' thay vì đợi đến khi họ đã đóng thẻ.

- Việc nhận diện chính xác các nhóm rủi ro giúp ngân hàng bảo vệ dòng doanh thu từ phí và lãi suất. Hơn nữa, việc hiểu rõ đặc điểm từng phân khúc khách hàng giúp ngân hàng đưa ra các sản phẩm cá nhân hóa, từ đó thắt chặt mối quan hệ và lòng trung thành của khách hàng đối với thương hiệu.

## 1.3. Mục tiêu nghiên cứu

Mục tiêu chính của tiểu luận là xây dựng thành công mô hình học máy có khả năng dự báo chính xác tình trạng rời bỏ của khách hàng. Để đạt được mục tiêu này, nghiên cứu tập trung vào các nhiệm vụ cụ thể:

- Tiền xử lý và Khai phá dữ liệu: Làm sạch dữ liệu, xử lý các biến định tính và thực hiện kỹ thuật đặc trưng (Feature Engineering) để tạo ra các chỉ tiêu đo lường hiệu quả chi tiêu.
- Phân khúc và Tinh lọc thông tin: Sử dụng K-Means để nhận diện các cụm hành vi rủi ro và áp dụng PCA để nén dữ liệu từ nhiều biến xuống 4 thành phần chính mà vẫn giữ được đặc trưng cốt lõi.
- Xây dựng và Đánh giá mô hình: Huấn luyện mô hình Random Forest, thực hiện tối ưu hóa tham số và đánh giá hiệu năng thông qua các thang đo chuyên dụng như Confusion Matrix, Recall và đường cong ROC/AUC.

## 1.4. Yêu cầu nghiên cứu

Mục tiêu cốt lõi của bài tiểu luận này là xây dựng thành công một hệ thống dự báo rủi ro dựa trên Machine Learning, có khả năng nhận diện chính xác tình trạng rời bỏ dịch vụ của khách hàng thẻ tín dụng. Để hiện thực hóa mục tiêu chiến lược này, nghiên cứu được thiết kế thông qua một lộ trình thực nghiệm chặt chẽ, tập trung vào ba nhóm nhiệm vụ trọng tâm.

Trước hết, nghiên cứu chú trọng vào giai đoạn Tiền xử lý và Khai phá dữ liệu nhằm xây dựng một bộ khung dữ liệu sạch và giàu thông tin. Quy trình này bắt đầu bằng việc làm sạch các sai lệch hệ thống, mã hóa các biến định tính để đưa về dạng số học phù hợp cho thuật toán. Đặc biệt, em vận dụng kỹ thuật đặc trưng (Feature Engineering) để kiến tạo nên các chỉ tiêu tài chính phái sinh, tiêu biểu là biến giá trị giao dịch trung bình. Việc biến đổi này đóng vai trò quyết định trong việc chuyển hóa các con số chi tiêu thô thành những chỉ báo có ý nghĩa về mặt hành vi, giúp mô hình "hiểu" sâu hơn về đẳng cấp và thói quen tiêu dùng thực tế của từng khách hàng.

Nhiệm vụ trọng tâm tiếp theo là quá trình ohân khúc và tinh lọc thông tin thông qua sự kết hợp giữa hai thuật toán học không giám sát mạnh mẽ. Bằng cách áp dụng K-Means Clustering, nghiên cứu thực hiện bóc tách tệp khách hàng thành các cụm hành vi rủi ro riêng biệt, từ đó cung cấp thêm bối cảnh nhóm cho bài toán dự báo. Đồng thời, kỹ thuật Phân tích thành phần chính (PCA) được triển khai như một giải pháp tối ưu để giải quyết hiện tượng đa cộng tuyến và nén không gian đặc trưng từ hàng chục biến số ban đầu xuống 4 thành phần chính (4 PCs). Quy trình tinh lọc này không chỉ giúp loại bỏ nhiễu mà còn đảm bảo giữ lại được những đặc trưng cốt lõi nhất, tạo tiền đề cho các mô hình dự báo vận hành tinh gọn và hiệu quả hơn.

Cuối cùng, nghiên cứu tập trung vào việc Xây dựng và Đánh giá mô hình dự báo bằng thuật toán Random Forest. Đây là giai đoạn hiện thực hóa khả năng phân loại khách hàng thông qua việc huấn luyện rừng cây quyết định và thực hiện tối ưu hóa tham số bằng phương pháp kiểm định chéo (Cross-Validation) để đảm bảo tính tổng quát hóa cao nhất. Nhằm đáp ứng yêu cầu khắt khe của quản trị rủi ro ngân hàng, hiệu năng của mô hình không chỉ được đo lường bằng độ chính xác đơn thuần mà còn được thẩm định chi tiết qua các thang đo chuyên dụng như Ma trận nhầm lẫn (Confusion Matrix), chỉ số Recall (khả năng bắt lỗi nợ xấu) và đường cong ROC/AUC. Sự phối hợp đồng bộ giữa các nhiệm vụ này kỳ vọng sẽ mang lại một công cụ dự báo sắc bén, hỗ trợ đắc lực cho ngân hàng trong việc chủ động giữ chân khách hàng rủi ro và tối ưu hóa lợi nhuận bền vững.

## 1.5. Hạn chế của đề tài và hướng phát triển nghiên cứu

Mặc dù nghiên cứu đã đạt được những kết quả khả quan trong việc xây dựng hệ thống dự báo rủi ro rời bỏ khách hàng với độ chính xác cao, đề tài vẫn tồn tại một số hạn chế nhất định cần được nhìn nhận một cách khách quan. Hạn chế đầu tiên nằm ở bản chất của nguồn dữ liệu sử dụng. Do các quy định nghiêm ngặt về bảo mật thông tin khách hàng trong ngành tài chính, nghiên cứu hiện đang sử dụng bộ dữ liệu chuẩn quốc tế thay vì dữ liệu thực tế trực tiếp từ hệ thống nội bộ của ngân hàng tại Việt Nam. Điều này dẫn đến việc các đặc thù về văn hóa tiêu dùng địa phương và các chính sách tín dụng đặc thù của thị trường trong nước chưa được phản ánh một cách trọn vẹn nhất trong mô hình.

Về khía cạnh kỹ thuật, nghiên cứu đã bộc lộ sự đánh đổi rõ rệt khi thực hiện giảm chiều dữ liệu. Việc vận dụng PCA để rút gọn về 4 thành phần chính tuy giúp mô hình tinh gọn và giải quyết triệt để hiện tượng đa cộng tuyến, nhưng cũng đồng thời làm mất đi khoảng 45% phương sai giải thích từ dữ liệu gốc. Thực nghiệm cho thấy chỉ số Recall của nhóm rủi ro đã sụt giảm từ 0.80 xuống 0.52 khi chuyển từ tập biến gốc sang các thành phần PCA, minh chứng rằng một số tín hiệu rủi ro vi mô đã bị triệt tiêu trong quá trình nén thông tin. Ngoài ra, mô hình hiện tại mới chỉ tập trung khai thác các dữ liệu hành vi nội tại như chi tiêu và dư nợ mà chưa tích hợp được các yếu tố kinh tế vĩ mô bên ngoài như biến động lãi suất, tỷ lệ lạm phát hay chỉ số tăng trưởng kinh tế — những tác nhân vốn có ảnh hưởng gián tiếp nhưng quan trọng đến sức khỏe tài chính của chủ thẻ.

Hướng phát triển nghiên cứu trong tương lai sẽ tập trung vào việc nâng cấp cả về chiều sâu thuật toán lẫn chiều rộng của dữ liệu. Về mặt kỹ thuật, việc ứng dụng các mô hình học máy tiên

tiến thuộc nhóm Boosting như XGBoost hoặc LightGBM là một ưu tiên hàng đầu để xử lý tốt hơn tình trạng dữ liệu mất cân bằng. Đặc biệt, theo tinh thần của các bài giảng về học sâu (Deep Learning), việc vận dụng mạng nơ-ron tái phát (RNN) hoặc kiến trúc LSTM sẽ cho phép ngân hàng phân tích dữ liệu giao dịch dưới dạng chuỗi thời gian (Time-series), từ đó bắt trọn được "dòng chảy hành vi" và đưa ra các cảnh báo rủi ro theo thời gian thực thay vì chỉ dựa trên các dữ liệu tĩnh tại một thời điểm.

Cuối cùng, nghiên cứu hướng tới việc tích hợp các công cụ giải thích mô hình (Explainable AI) như SHAP hoặc LIME để giải mã "hộp đen" của các thuật toán phức tạp. Việc hiểu rõ biến số nào đang đóng góp bao nhiêu phần trăm vào xác suất rủi ro của từng cá nhân cụ thể không chỉ giúp tăng tính minh bạch trong quá trình phê duyệt tín dụng mà còn là cơ sở để ngân hàng xây dựng các chiến lược giữ chân khách hàng cá nhân hóa một cách bền vững và hiệu quả hơn.

# PHẦN NỘI DUNG

## 2.1. CƠ SỞ LÝ THUYẾT

### 2.1.1 Tổng quan về Học Thống kê (Statistical Learning)

Mối quan hệ giữa hành vi khách hàng và rủi ro được mô hình hóa qua phương trình:

$$Y = f(X) + \epsilon$$

Trong đó $X = (X_1, X_2, \dots, X_p)$ là vector đặc trưng.

Hàm hồi quy (Regression Function): $f(x) = E(Y \mid X = x)$ đại diện cho giá trị kỳ vọng của $Y$khi biết $X$. Trong bài toán phân loại, đây chính là xác suất hậu nghiệm $Pr(Y = 1 \mid X = x)$.

Sai số không thể giảm bớt (Irreducible Error): $\mathrm{Var}(\epsilon)$ đại diện cho những biến động ngẫu nhiên không nằm trong tập dữ liệu (ví dụ: tâm lý đột xuất của khách hàng).

Đánh đổi Bias-Variance: Tổng sai số dự báo (Expected Test MSE) được phân rã thành:

$$E(y_0 - \hat{f}(x_0))^2 = \mathrm{Var}(\hat{f}(x_0)) + [\mathrm{Bias}(\hat{f}(x_0))]^2 + \mathrm{Var}(\epsilon)$$

*Ý nghĩa:* Một mô hình phức tạp như Random Forest sẽ giảm thấp Bias nhưng cần kỹ thuật Bagging để kiểm soát Variance.

### 2.1.2 Học không giám sát (Unsupervised Learning)

#### *2.1.2.1. Phân cụm K-Means (K-Means Clustering)*

Thuật toán K-Means mục tiêu phân chia $n$ quan sát thành $K$ cụm $(C_1, C_2, \dots, C_K)$ sao cho tổng biến thiên nội cụm là nhỏ nhất:

$$\min_{C_1,\dots,C_K} \sum_{k=1}^{K} WCV(C_k)$$

Trong đó, biến thiên nội cụm ($WCV$) thường được tính bằng bình phương khoảng cách Euclidean:

$$WCV(C_k) = \frac{1}{|C_k|} \sum_{i,i' \in C_k} \sum_{j=1}^{p} (x_{ij} - x_{i'j})^2$$

Thuật toán vận hành qua hai bước lặp: (1) Gán mỗi điểm vào cụm có tâm (centroid) gần nhất và (2) Cập nhật tâm cụm bằng trung bình cộng tọa độ các điểm trong cụm đó.

### *2.1.2.2. Phân tích thành phần chính (PCA)*

PCA là kỹ thuật giảm chiều dữ liệu bằng cách tạo ra các tổ hợp tuyến tính của các biến gốc. Thành phần chính thứ nhất ($Z_1$) được xác định bởi:

$$Z_1 = \phi_{11}X_1 + \phi_{21}X_2 + \cdots + \phi_{p1}X_p$$

Với điều kiện:

$$\sum_{j=1}^{p} \phi_{j1}^2 = 1$$

và $Z_1$ có phương sai lớn nhất. Các thành phần tiếp theo ($Z_2, Z_3, \ldots$)

$$\mathrm{Cov}(Z_i, Z_j) = 0$$

phải chính giao (không tương quan) với các thành phần trước đó. Trong kinh tế lượng, PCA cực kỳ hiệu quả để xử lý hiện tượng **Đa cộng tuyến (Multicollinearity)** và giúp trực quan hóa dữ liệu đa chiều trên mặt phẳng 2D. Các hệ số $\phi_{jm}$ cho biết mức độ đóng góp (trọng số) của biến gốc vào PC. Trong bài toán này, PC4 thường đóng vai trò là chỉ báo về sự thay đổi (Change) hành vi theo thời gian.

## 2.1.3 Các mô hình dự báo (Supervised Learning)

### *2.1.3.1. Hồi quy Tuyến tính và Hồi quy Logistic*

Hồi quy Tuyến tính (OLS): Ước lượng mối quan hệ dưới dạng $Y = \beta_0 + \beta_1 X_1 + \cdots$. Tuy nhiên, với biến mục tiêu nhị phân, OLS bộc lộ nhược điểm do dự báo xác suất có thể nằm ngoài khoảng $[0, 1]$

Hồi quy Logistic: Mô hình hóa xác suất rời bỏ qua hàm Logit:

$$\log\left(\frac{p(x)}{1-p(x)}\right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$$

Ước lượng: Các tham số $\beta$được tìm thông qua việc tối đa hóa hàm Likelihood:

$$\ell(\beta) = \prod_{i:y_i=1} p(x_i) \prod_{i:y_i=0} (1 - p(x_i))$$

Odds Ratio: $e^{\beta_i}$ cho biết khi $X_i$tăng 1 đơn vị, khả năng khách hàng rời đi so với ở lại tăng bao nhiêu lần.

Mô hình này cho phép tính toán Odds Ratio: $p(X)/(1-p(X))$, giúp giải thích rằng khi biến $X_i$ tăng 1 đơn vị, cơ hội xảy ra sự kiện tăng/giảm bao nhiêu lần.

### *2.1.3.2. Cây quyết định và Random Forest*

**Random Forest** (Rừng ngẫu nhiên) là một thuật toán học máy thuộc nhóm **học có giám sát** (supervised learning), được sử dụng phổ biến cho cả bài toán **phân loại** (classification) và **hồi quy** (regression). Đây là một dạng của **học tập hợp** (ensemble learning), trong đó nhiều "mô hình yếu" (cụ thể là các cây quyết định - decision trees) được kết hợp lại để tạo thành một mô hình dự đoán mạnh mẽ và chính xác hơn. Thay vì dựa vào kết quả của một cây duy nhất, Random Forest xây dựng một “khu rừng” gồm hàng trăm cây hoặc nghìn cây quyết định độc lập.

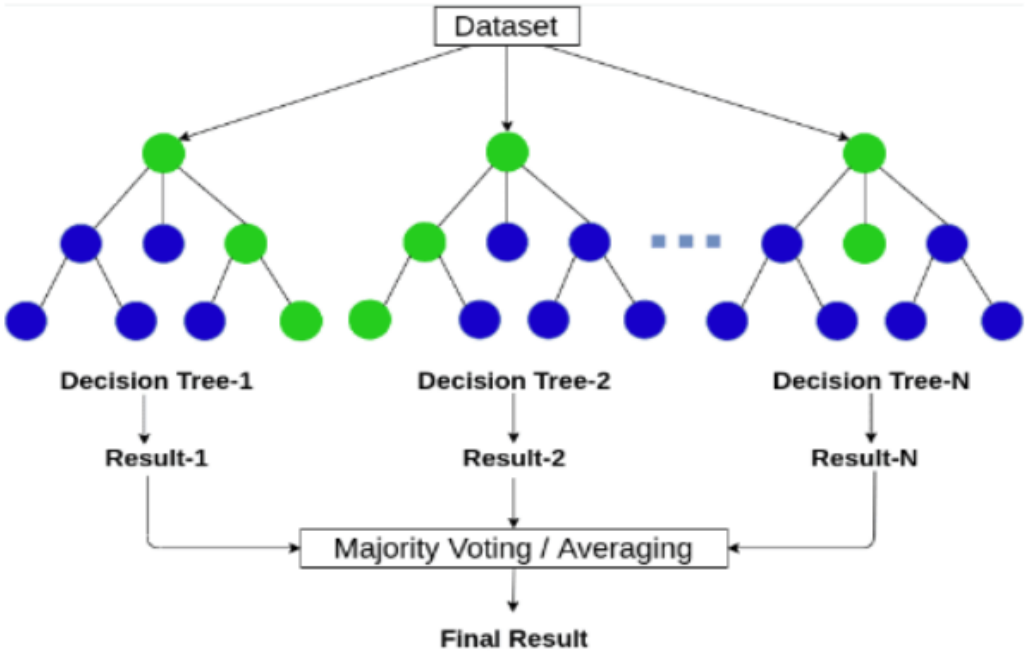

Đối với những bài toán phân loại thì mỗi cây trong rừng sẽ đưa ra một dự đoán. Kết quả cuối cùng là lớp nhận được số phiếu cao nhất (Ví dụ, giả sử chúng ta có 100 cây quyết định. Đối với một mẫu mới, nếu 60 cây dự đoán rằng mẫu đó thuộc lớp A, và 40 cây dự đoán rằng mẫu đó thuộc lớp B, thì Random Forest sẽ dự đoán rằng mẫu đó thuộc lớp A (vì nó nhận được số phiếu cao hơn).

$$\hat{y} = mode\{\hat{y}^{(1)}, \hat{y}^{(2)}, \dots, \hat{y}^{(B)}\}$$

Đối với bài toán hồi quy, kết quả cuối cùng là giá trị trung bình của các dự đoán từ tất cả các cây.[2]

$$\hat{y} = \frac{1}{B}\sum_{b=1}^{B} \hat{y}^{(b)}$$

Random Forest cải tiến từ cây quyết định bằng kỹ thuật Bagging (Bootstrap Aggregating). Thuật toán lấy mẫu lặp lại (Bootstrap) để xây dựng nhiều cây độc lập. Điểm khác biệt quan trọng là tại mỗi nút chia, thuật toán chỉ chọn ngẫu nhiên một tập con các biến số ($m \approx \sqrt{p}$) để xem xét. Điều này giúp "làm mất tương quan" (decorrelate) giữa các cây, từ đó giảm phương sai và tăng độ chính xác vượt trội cho mô hình.

$$G = \sum_{k=1}^{K} \hat{p}_{mk}\,(1 - \hat{p}_{mk})$$

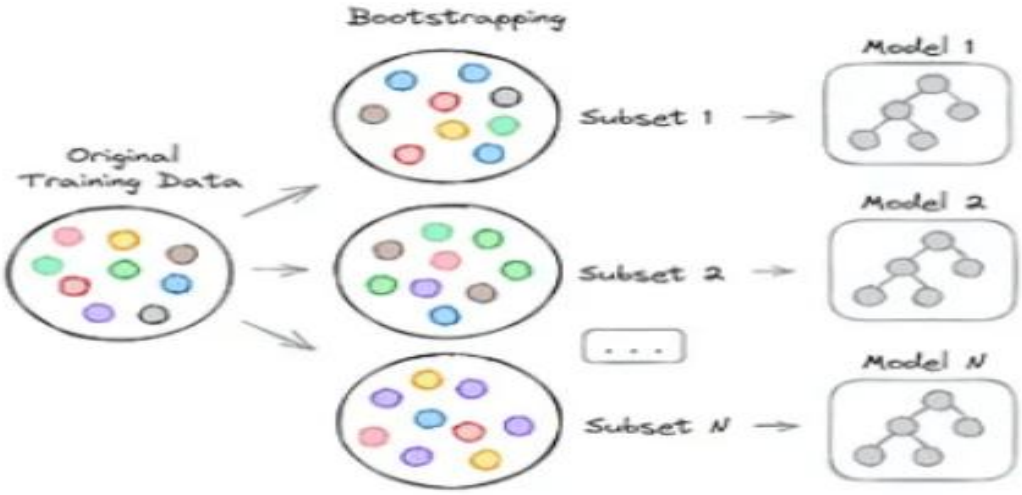


Việc lựa chọn thuật toán Random Forest làm mô hình dự báo chủ đạo trong nghiên cứu này dựa

[2] https://machinelearningcoban.com/tabml_book/index.html

trên sự cân nhắc kỹ lưỡng giữa năng lực kỹ thuật và tính ứng dụng thực tiễn. Xét về mặt ưu điểm, Random Forest thể hiện sức mạnh vượt trội thông qua độ chính xác dự báo cao nhờ vào cơ chế học kết hợp (Ensemble Learning). Bằng cách tổng hợp kết quả từ hàng trăm cây quyết định độc lập, mô hình có khả năng bắt trọn các mối quan hệ phi tuyến phức tạp trong hành vi khách hàng[3]. Đặc biệt, dựa trên nguyên lý đánh đổi Bias-Variance, thuật toán này giúp giảm thiểu đáng kể hiện tượng quá khớp (Overfitting). Việc thực hiện lấy mẫu ngẫu nhiên có hoàn lại (Bootstrap) và trung bình hóa kết quả dự báo giúp mô hình trở nên ổn định và ít nhạy cảm hơn với các yếu tố nhiễu (noise) của dữ liệu tài chính so với một cây quyết định đơn lẻ.

Bên cạnh đó, Random Forest còn cung cấp hai công cụ phân tích cực kỳ giá trị cho nhà quản trị ngân hàng. Thứ nhất là khả năng đánh giá tầm quan trọng của đặc trưng (Feature Importance), cho phép chúng tôi xếp hạng chính xác các biến số như tần suất giao dịch hay dư nợ đang đóng góp bao nhiêu phần trăm vào khả năng phân loại rủi ro. Thứ hai là cơ chế ước lượng lỗi nội bộ thông qua chỉ số Out-of-Bag (OOB). Với khoảng 37% dữ liệu không được dùng để huấn luyện cho mỗi cây, mô hình có thể tự thẩm định hiệu năng ngay trong quá trình xây dựng, giúp cung cấp một thước đo sai số khách quan mà không bắt buộc phải tách riêng một tập kiểm tra trong các giai đoạn huấn luyện ban đầu.

Tuy nhiên, nghiên cứu cũng nhìn nhận một cách khách quan những hạn chế nhất định của phương pháp này. Về mặt vận hành, Random Forest có cấu trúc rất phức tạp, đòi hỏi tài nguyên bộ nhớ và thời gian xử lý lớn hơn nhiều so với các mô hình tuyến tính, điều này có thể gây áp lực lên hệ thống tính toán nếu dữ liệu khách hàng tăng trưởng quy mô lớn. Về mặt diễn giải, mô hình này thường bị coi là một "hộp đen" (Black Box) do tính chất khó giải thích. Khác với mô hình Logistic Regression vốn minh bạch về các hệ số tác động biên, việc giải thích chi tiết logic đằng sau sự biểu quyết của hàng trăm cây quyết định cho một trường hợp cụ thể là một thách thức lớn. Dẫu vậy, trong bối cảnh quản trị rủi ro tín dụng hiện đại, khi độ chính xác và khả năng nhận diện sớm nợ xấu được đặt lên hàng đầu, Random Forest vẫn là một giải pháp tối ưu, mang lại sự cân bằng hiệu quả giữa sức mạnh kỹ thuật và giá trị thực tiễn cho ngân hàng.[4]

### *2.3.3. Điều chuẩn Lasso ($\ell_1$ Regularization)*

Lasso (Least Absolute Shrinkage and Selection Operator) là một biến thể tiên tiến của mô hình hồi quy tuyến tính, được bổ sung thêm thành phần phạt (penalty term) dựa trên tổng giá trị tuyệt đối của các hệ số hồi quy, hay còn gọi là kỹ thuật sử dụng chuẩn $\ell_1$. [5]Quá trình hiệu chỉnh (tuning) trong Lasso thực chất là việc tìm kiếm giá trị tối ưu cho tham số điều chuẩn $\lambda$ (alpha).

---

[3] https://aicandy.vn/thuat-toan-random-forest-giai-thich-chi-tiet-va-ung-dung/#4_Uu_diem_va_nhuoc_diem_cua_Random_Forest

[4] https://aicandy.vn/thuat-toan-random-forest-giai-thich-chi-tiet-va-ung-dung/#4_Uu_diem_va_nhuoc_diem_cua_Random_Forest

[5] How to Choose Tuning Parameters in Lasso and Ridge Regression?

Tham số này đóng vai trò quyết định trong việc kiểm soát mức độ thu nhỏ của các hệ số và độ phức tạp tổng thể của mô hình.

Về mặt vận hành, khi $\lambda = 0$, mô hình sẽ tương đương với hồi quy bình phương cực tiểu (OLS) thông thường. Ngược lại, khi giá trị $\lambda$ tăng dần, nhiều hệ số hồi quy sẽ bị ép về mức 0 một cách chính xác. Đặc tính này cho phép thuật toán thực hiện việc lựa chọn biến tự động (Automatic Feature Selection), chỉ giữ lại những đặc trưng mang lại giá trị dự báo quan trọng nhất cho mô hình.

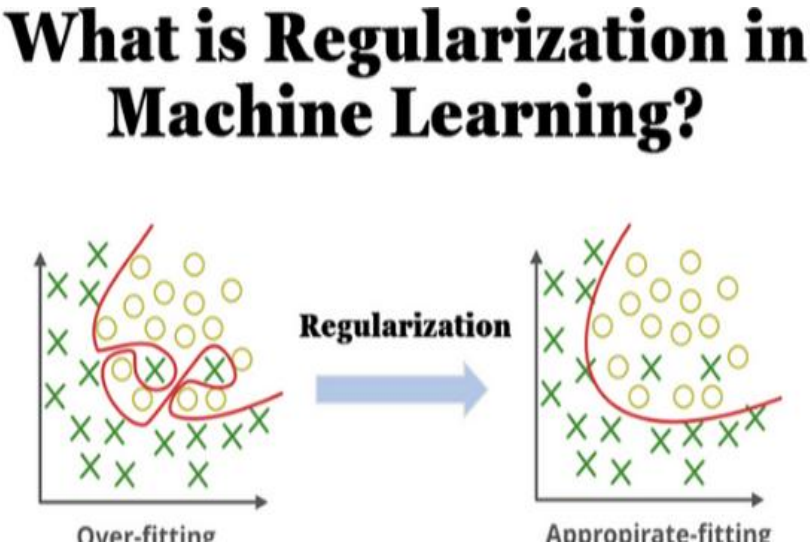


Một yêu cầu bắt buộc trước khi thực hiện hiệu chỉnh Lasso là bước chuẩn hóa dữ liệu (Standardization). Do Lasso nhạy cảm trực tiếp với độ lớn của các biến số, nếu không chuẩn hóa, các biến có đơn vị đo lường lớn sẽ bị mô hình "phạt" nặng hơn một cách bất công so với các biến có thang đo nhỏ, dẫn đến kết quả ước lượng bị sai lệch.

Để xác định giá trị $\lambda$ tối ưu, phương pháp kiểm chứng chéo (Cross-validation) thường được ưu tiên sử dụng. Kỹ thuật này giúp ước lượng trực tiếp sai số dự báo trên các tập dữ liệu độc lập, từ đó tìm ra điểm cân bằng lý tưởng nhất trong bài toán đánh đổi giữa độ chệch (Bias) và phương sai (Variance). Bên cạnh đó, các tiêu chí thông tin như AIC (Akaike Information Criterion) hoặc BIC (Bayesian Information Criterion) cũng là những công cụ hữu hiệu để nhà nghiên cứu lựa chọn mô hình dựa trên sự đánh đổi giữa độ khớp của dữ liệu và số lượng tham số sử dụng.[6] Cuối cùng, việc vận dụng quy tắc một sai số tiêu chuẩn (One Standard Error Rule) cho phép chúng ta lựa chọn được mô hình thưa nhất (tối giản nhất) mà vẫn đảm bảo sai số nằm trong phạm vi chấp nhận được so với mô hình có sai số tối thiểu, đảm bảo tính bền vững cho hệ thống dự báo rủi ro.

Để tránh hiện tượng đa cộng tuyến và quá khớp, Lasso thêm hình phạt vào hàm mất mát:

$$\min\left\{\text{Loss}+\lambda \sum_{j=1}^{p} |\beta_j|\right\}$$

Trong đó:

- Phần đầu là RSS: Sai số giữa dự báo và thực tế.

[6] Lasso: Algorithms - MyWeb

- Phần sau là Hình phạt L1 ($\ell_1$ penalty): $\sum | \beta_j |$.
- $\lambda$ (Lambda): Là tham số điều chỉnh. Nếu $\lambda$ càng lớn, hình phạt càng nặng, các hệ số $\beta$ sẽ bị ép về 0.

*Ý nghĩa:* Lasso có khả năng ép các hệ số $\beta$ về đúng bằng 0, đóng vai trò như một bộ lọc biến (feature selection) tự động cho ngân hàng.

### 2.1.4. Đánh giá hiệu năng mô hình (Model Evaluation)

Trong bài toán dự báo rủi ro khách hàng, việc chỉ sử dụng độ chính xác toàn cục (Accuracy) làm thước đo duy nhất thường dẫn đến những kết luận sai lệch, bởi đặc thù của dữ liệu tài chính thường rơi vào trạng thái mất cân bằng (Imbalanced Data) giữa nhóm khách hàng tốt và khách hàng xấu. Do đó, nghiên cứu này tập trung vào việc phân tích các chỉ số chuyên sâu để đánh giá hiệu quả thực hiện của mô hình. Trước hết, Ma trận nhầm lẫn (Confusion Matrix) được sử dụng như một công cụ nền tảng để phân định rõ ràng giữa các kịch bản dự báo đúng (True Positive, True Negative) và các sai sót trong phân loại (False Positive, False Negative).

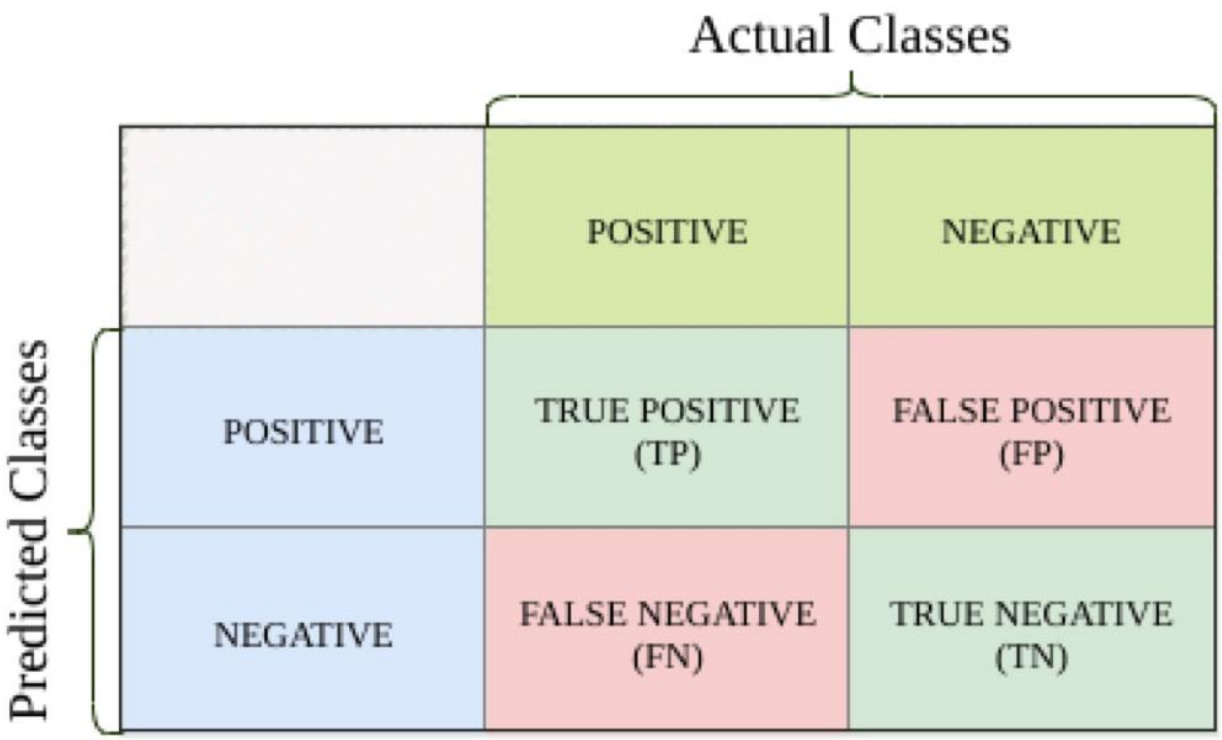


Đặc biệt, từ góc độ quản trị rủi ro tại ngân hàng, chỉ số Recall (hay Sensitivity), được tính bằng công thức $TP/(TP + FN)$, đóng vai trò là tiêu chí ưu tiên hàng đầu. Chỉ số này phản ánh năng lực của mô hình trong việc nhận diện chính xác các đối tượng thực sự có nguy cơ, từ đó giúp ngân hàng cực tiểu hóa rủi ro bỏ sót các khoản nợ xấu tiềm ẩn. Tuy nhiên, để đảm bảo tính khách quan và tránh việc mô hình quá thiên kiến, chỉ số F1-Score — trung bình điều hòa giữa Precision và Recall — được đưa vào để đánh giá độ bền vững và khả năng cân bằng của thuật toán. Cuối

cùng, năng lực phân loại tổng quát của mô hình được minh chứng thông qua diện tích dưới đường cong ROC (AUC-ROC). Một mô hình dự báo rủi ro được coi là có giá trị ứng dụng thực tiễn cao khi đạt được giá trị AUC vượt ngưỡng 0.8, đảm bảo sự tin cậy trong việc ra quyết định cấp tín dụng hoặc giữ chân khách hàng.

# 2.2. NỘI DUNG NGHIÊN CỨU VÀ PHƯƠNG PHÁP NGHIÊN CỨU

## 2.2.1. Nội dung nghiên cứu

Nghiên cứu này được thực hiện dựa trên một chuỗi các nội dung logic, đi từ việc thấu hiểu dữ liệu thô đến việc xây dựng các giải pháp quản trị thực tiễn. Trước hết, em tập trung vào việc phân tích đặc điểm hành vi khách hàng thông qua các phương pháp thống kê mô tả, nhằm phác thảo chân dung của nhóm khách hàng hiện hữu và nhóm khách hàng rời bỏ dựa trên các biến số tài chính then chốt như hạn mức tín dụng, dư nợ và cường độ giao dịch. Trên nền tảng đó, các phương pháp học không giám sát được vận dụng để phân khúc khách hàng, trong đó thuật toán K-Means đóng vai trò nhận diện các nhóm hành vi tương đồng như nhóm chi tiêu cao, nhóm 'ngủ đông' hay nhóm có áp lực nợ lớn.

Song song với việc phân khúc, nghiên cứu tiến hành rút gọn không gian đặc trưng và xử lý nhiễu bằng kỹ thuật PCA nhằm giải quyết triệt để hiện tượng đa cộng tuyến giữa các biến tài chính, từ đó giúp mô hình dự báo trở nên tinh gọn và hiệu quả hơn. Trọng tâm của nghiên cứu nằm ở bước xây dựng và tối ưu hóa các mô hình dự báo, nơi các thuật toán học máy được triển khai để tính toán chính xác xác suất rời bỏ dịch vụ, đồng thời thực hiện so sánh hiệu năng giữa cách tiếp cận tuyến tính và phi tuyến tính. Cuối cùng, dựa trên các kết quả định lượng từ ma trận trọng số

(Loadings) và tầm quan trọng của biến (Feature Importance), em đề xuất các giải pháp quản trị rủi ro và khuyến nghị chính sách cụ thể cho ngân hàng, nhằm tối ưu hóa chiến lược giữ chân khách hàng và nâng cao hiệu quả hoạt động tín dụng.

### 2.2.2. Phương pháp nghiên cứu

Nghiên cứu áp dụng quy trình khai phá dữ liệu qua 4 giai đoạn cụ thể, tập trung vào việc tối ưu hóa biến số để đạt hiệu quả dự báo cao nhất.

### *3.2.1. Lựa chọn và Xây dựng biến (Feature Selection & Engineering)*

Trong giai đoạn xây dựng mô hình dự báo rủi ro rời bỏ (Attrition_Flag), việc xác định các biến số đầu vào đóng vai trò quyết định đến độ chính xác và tính giải thích của mô hình. Từ tập dữ liệu thô ban đầu, em thực hiện sàng lọc và giữ lại bốn nhóm biến số cốt lõi phản ánh toàn diện chân dung khách hàng. Cụ thể, nhóm biến nhân khẩu học (độ tuổi, giới tính, trình độ học vấn, tình trạng hôn nhân) được kết hợp cùng nhóm biến tài chính (hạn mức tín dụng, dư nợ và tỷ lệ sử dụng nợ) để tạo nên khung dữ liệu nền tảng. Bên cạnh đó, các biến hành vi giao dịch và biến tương tác trong vòng 12 tháng qua cũng được đưa vào mô hình nhằm bắt trọn những thay đổi trong thói quen sử dụng dịch vụ của khách hàng.

Nhằm nâng cao năng lực dự báo, nghiên cứu chú trọng vào kỹ thuật đặc trưng đặc trưng (Feature Engineering) thông qua việc tạo mới hai biến số mang tính chiến lược. Thứ nhất là biến Avg_Trans_Value (Giá trị giao dịch trung bình), được xây dựng bằng cách tính tỷ lệ giữa tổng số tiền và số lượng giao dịch, nhằm khắc phục hạn chế về tính đơn lẻ của dữ liệu chi tiêu thô. Thứ hai là biến Customer_Segment, kết quả từ thuật toán phân cụm K-Means, đóng vai trò phân loại khách hàng vào các nhóm hành vi đặc trưng (VIP, Revolvers, Dormant) và được đưa vào mô hình dưới dạng biến giả (dummy variables).

Cuối cùng, để tối ưu hóa hiệu suất tính toán và tránh hiện tượng nhiễu thông tin, em quyết định loại bỏ biến CLIENTNUM do đây chỉ là mã định danh cá nhân, không mang giá trị dự báo hành vi. Các cột thông tin bổ trợ khác không phục vụ mục tiêu nghiên cứu cũng được lược bỏ, đảm bảo không gian đặc trưng của mô hình luôn tinh gọn và tập trung vào những tín hiệu rủi ro thực sự.

### *3.2.2. Quy trình xử lý và Chuẩn hóa (Preprocessing)*

Giai đoạn tiền xử lý dữ liệu đóng vai trò then chốt trong việc đảm bảo tính khách quan và độ chính xác cho các thuật toán học máy. Trước hết, kỹ thuật One-hot Encoding được áp dụng cho các biến định tính như *Trình độ học vấn (Education_Level)*, *Phân lớp thu nhập (Income_Category)* và đặc biệt là biến phân khúc khách hàng mới được tạo lập *Customer_Segment*. Việc chuyển đổi này giúp đưa các dữ liệu phi số học về dạng ma trận số học, tạo điều kiện cho máy tính thực hiện các phép toán mô hình hóa.

Kế tiếp, nghiên cứu sử dụng phương pháp StandardScaler để chuẩn hóa toàn bộ các biến định lượng về cùng một thang đo với kỳ vọng bằng 0 và độ lệch chuẩn bằng 1. Theo lý thuyết học

máy (Slide bài giảng), đây là bước bắt buộc để các thuật toán dựa trên khoảng cách như K-Means (khoảng cách Euclidean) và các phương pháp dựa trên phương sai như PCA hoạt động chính xác. Việc đưa dữ liệu về cùng một quy mô giúp loại bỏ tình trạng các biến có đơn vị lớn (như *Credit Limit*) áp đảo và làm sai lệch trọng số của các biến có đơn vị nhỏ hơn, từ đó nâng cao tính ổn định của mô hình.

### *3.2.3. Quy trình Mô hình hóa và Giảm chiều dữ liệu*

Trong giai đoạn mô hình hóa, nghiên cứu tập trung vào việc tinh lọc thông tin và xây dựng hệ thống dự báo đa tầng. Cụ thể, kỹ thuật Phân tích thành phần chính (PCA) được vận dụng nhằm giải quyết triệt để hiện tượng đa cộng tuyến – một thách thức phổ biến trong dữ liệu ngân hàng khi các biến tài chính như *Credit_Limit* và *Avg_Open_To_Buy* thường có sự tương quan rất mạnh. Qua quá trình phân tích, em thực hiện trích xuất 4 thành phần chính (4 PCs) mang tính đại diện cao nhất cho toàn bộ tập dữ liệu, phản ánh 4 nhóm nhân tố cốt lõi: (1) Năng lực tín dụng, (2) Cường độ giao dịch, (3) Thâm niên khách hàng và (4) Xu hướng biến động hành vi.

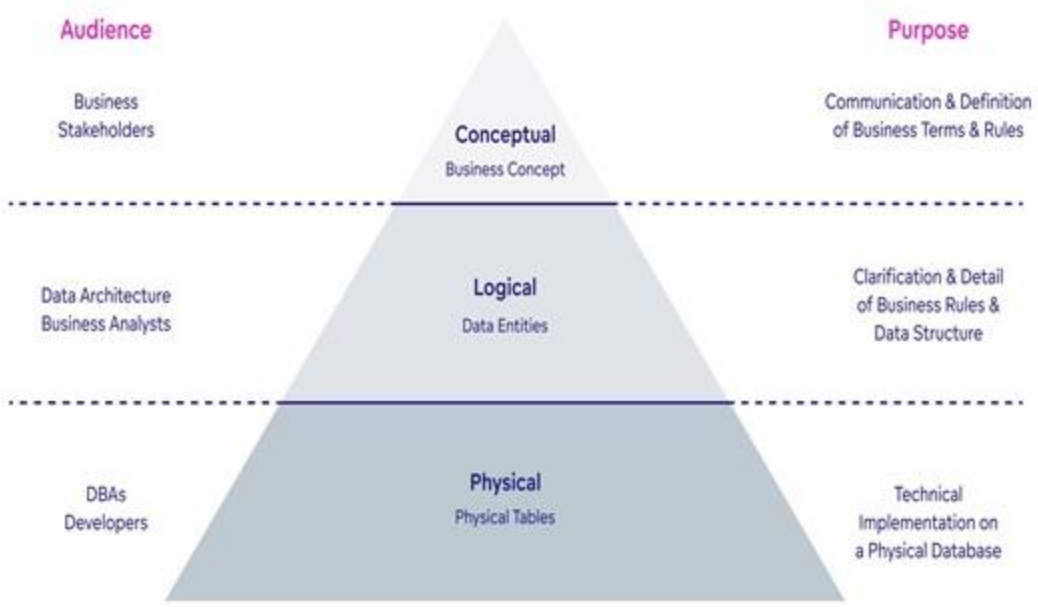


Dựa trên không gian đặc trưng đã được tối ưu hóa, quá trình huấn luyện mô hình được triển khai bắt đầu với Hồi quy Logistic trong vai trò mô hình cơ sở (Baseline). Cách tiếp cận này cho phép em không chỉ đưa ra các dự báo sơ bộ mà còn giúp nhà quản trị hiểu rõ bản chất của rủi ro thông qua các hệ số tác động biên và chỉ số Odds Ratio (Tỷ lệ chênh lệch). Việc xác định được hướng tác động của từng nhóm thành phần chính là cơ sở quan trọng để ngân hàng đưa ra các chính sách can thiệp kịp thời đối với từng phân khúc khách hàng cụ thể.

## 2.3. GIỚI THIỆU VÀ XỬ LÝ DỮ LIỆU

### 2.3.1. Giới thiệu dữ liệu:

Các biến, kiểu dữ liệu của biến và ý nghĩa trong thực tiễn của các biến được thể hiện trong bảng sau đây:

| STT | Tên biến số | Kiểu dữ liệu | Ý nghĩa trong thực tiễn |
|---|---|---|---|
| **I** | **Biến Mục Tiêu** | | |
| 1 | Attrition_Flag | Phân loại (Categorical) | Tình trạng khách hàng: Hiện hữu (Existing) hoặc Đã rời bỏ (Attrited). |
| **II** | **Nhóm Nhân khẩu học** | | |
| 2 | Customer_Age | Số nguyên | Độ tuổi của khách hàng (Phản ánh sự ổn định tài chính). |
| 3 | Gender | Phân loại | Giới tính khách hàng. |
| 4 | Dependent_count | Số nguyên | Số người phụ thuộc (Gánh nặng tài chính). |
| 5 | Education_Level | Phân loại | Trình độ học vấn (Tỉ lệ thuận với mức thu nhập kỳ vọng). |
| 6 | Marital_Status | Phân loại | Tình trạng hôn nhân. |
| **III** | **Nhóm Tài chính & Thẻ** | | |
| 7 | Income_Category | Phân loại | Phân lớp thu nhập hàng năm của khách hàng. |
| 8 | Credit_Limit | Số thực | Hạn mức tín dụng tối đa được cấp. |

| | | | |
|---|---|---|---|
| 9 | Total_Revolving_Bal | Số thực | Tổng dư nợ thẻ chưa thanh toán (Mức độ vay nợ). |
| 10 | Avg_Open_To_Buy | Số thực | Hạn mức tín dụng còn lại chưa sử dụng. |
| 11 | Avg_Utilization_Ratio | Số thực | Tỷ lệ sử dụng hạn mức (Dư nợ / Hạn mức). |
| **IV** | **Nhóm Hành vi giao dịch** | | |
| 12 | Total_Trans_Amt | Số thực | Tổng số tiền giao dịch trong 12 tháng qua. |
| 13 | Total_Trans_Ct | Số thực | Tổng số lần quẹt thẻ trong 12 tháng qua (Độ gắn kết). |
| 14 | Total_Amt_Chng_Q4_Q1 | Số thực | Sự thay đổi giá trị giao dịch giữa Quý 4 và Quý 1. |
| **V** | **Biến tạo mới (Engineered)** | | |
| 15 | **Avg_Trans_Value** | Số thực | Giá trị trung bình mỗi lần quẹt thẻ (Tiêu dùng trung bình). |
| 16 | **Customer_Segment** | Phân loại | Phân khúc khách hàng từ thuật toán K-Means. |

**Bước 1: Thu nhập & Tiền xử lý dữ liệu**

Nạp dữ liệu gốc

Loại bỏ các biến định danh và biến nhiễu

Xử lý các giá trị thiếu và dữ liệu trùng lặp

**Bước 2: Kỹ thuật đặc trưng (Feature Engineering)**

Tạo biến Avg_Trans_Value để đo lường chất lượng chi tiêu.

Áp dụng K-Means Clustering để tạo biến phân khúc khách hàng (Customer_Segment).

Chuẩn hóa dữ liệu ( StandardScaler)

Mã hóa biến định tính (One-hot Encoding)

**Bước 3: Tinh lọc dữ liệu và giảm chiều**

Áp dụng PCA trích xuất 4 thành phần chính PCs để xử lý đa cộng tuyến

**Bước 4: Huấn luyện mô hình (Model Training)**

Chia tập dữ liệu (70% Train / 30% Test).

Chạy **Logistic Regression** kết hợp điều chỉnh Lasso

Chạy **Random Forest** kết hợp Tối ưu hóa tham số qua Cross-Validation.

**Bước 5: Đánh giá & So sánh (Evaluation)**

Đo lường Accuracy, Recall, F1-Score.

Vẽ Confusion Matrix, ROC/AUC và Feature Importance.

Đối chiếu tính nhất quán giữa phân cụm (K-Means) và dự báo (Random Forest).

**Bước 6: Kết luận & Giải pháp**

Lựa chọn mô hình tối ưu cho ngân hàng.

Đề xuất chính sách giữ chân khách hàng rủi ro.

## 2.3.2. Thu nhập tiền xử lý dữ liệu:

Nghiên cứu sử dụng bộ dữ liệu hành vi thẻ tín dụng của khách hàng ngân hàng thương mại. Tập dữ liệu ban đầu bao gồm 10,127 quan sát với 23 biến số. Bước đầu tiên trong quy trình xử lý là kiểm tra tính toàn vẹn của dữ liệu. Em tiến hành rà soát các giá trị rỗng (missing values) và các bản ghi trùng lặp để đảm bảo tính khách quan cho mô hình.

```
df.isnull().sum()
df.duplicated().sum()
```

```
np.int64(0)
```

Sau khi xác nhận dữ liệu không có giá trị rỗng, em tiến hành loại bỏ các cột không có ý nghĩa dự báo bao gồm: CLIENTNUM (mã định danh) và hai cột kết quả từ mô hình Naive Bayes có sẵn ở cuối bảng dữ liệu. Việc loại bỏ này giúp tập trung vào các đặc trưng hành vi gốc của khách hàng.

Trước khi đưa vào mô hình dự báo chính thức, em thực hiện kiểm tra tương quan để nhận diện hiện tượng đa cộng tuyến. Việc các biến tài chính tương quan quá mạnh sẽ làm giảm tính ổn định của các hệ số hồi quy.

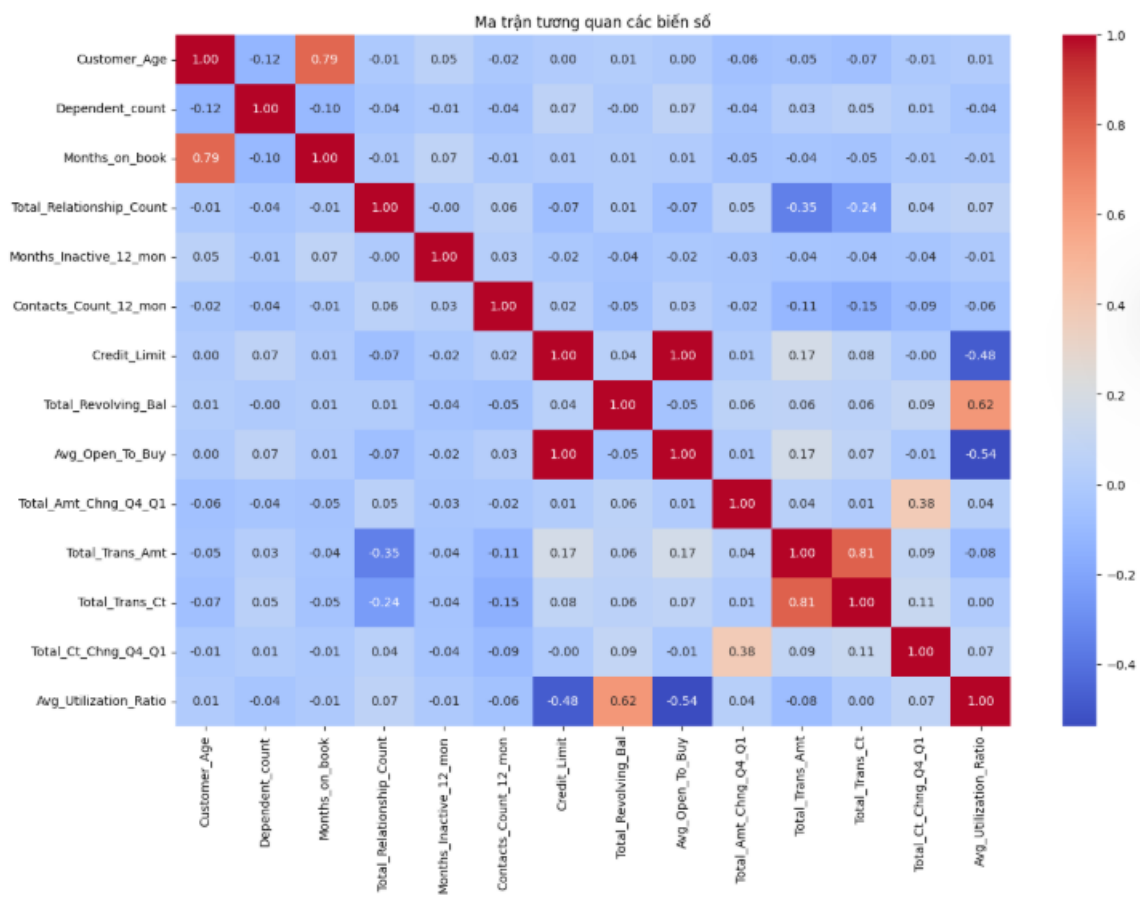

Thông qua việc quan sát biểu đồ Heatmap, em nhận thấy có hiện tượng đa cộng tuyến (Multicollineartity) ở biến Credit_Limit và Avg_Open_To_Buy có hệ số tương quan hoàn hảo bằng 1.00. Điều này cho thấy hai biến này chứa thông tin trùng lặp hoàn toàn. Ngoài ra, Total_Trans_Amt và Total_Trans_Ct cũng có tương quan rất mạnh (0.81). Bên cạnh đó, ta còn có thể thấy dấu hiệu rời bỏ bởi biến mục tiêu (Target) có mối tương quan đáng kể với Total_Trans_Ct (Tần suất giao dịch) và Total_Revolving_Bal (Dư nợ thẻ).

➔ Vì vậy, để mô hình dự báo không bị nhiễu và quá khớp do hiện tượng đa cộng tuyến, nghiên cứu sẽ áp dụng kỹ thuật PCA ở phần sau nhằm nén các biến có tương quan mạnh này thành các thành phần chính độc lập, giúp mô hình Random Forest đạt được hiệu quả tối ưu hơn.

## 2.4. KỸ THUẬT ĐẶC TRƯNG (FEATURE ENGINEERING)

Trong quy trình xây dựng mô hình học máy, kỹ thuật đặc trưng (Feature Engineering) được xem là khâu then chốt quyết định đến sức mạnh dự báo của thuật toán. Thay vì chỉ dựa trên các biến số thô từ hệ thống, em thực hiện biến đổi và tổ hợp dữ liệu để tạo ra các chỉ tiêu mang tính chiến lược, giúp mô hình 'hiểu' sâu hơn về hành vi kinh tế của khách hàng.

### 2.4.1. Xây dựng biến mới

Nghiên cứu xây dựng biến Avg_Trans_Value (Giá trị trung bình mỗi giao dịch) bằng cách tính tỷ lệ giữa tổng doanh số chi tiêu (Total_Trans_Amt) và tổng số lần quẹt thẻ (Total_Trans_Ct). Trong phân tích tài chính, biến số này mang ý nghĩa quan trọng hơn các giá trị tổng mức. Một khách hàng có tổng chi tiêu lớn nhưng chỉ qua một vài giao dịch đơn lẻ thường có độ gắn kết thấp hơn so với nhóm khách hàng chi tiêu đều đặn với giá trị trung bình ổn định. Biến phái sinh này giúp mô hình loại bỏ các yếu tố nhiễu từ những giao dịch đột biến và tập trung vào bản chất 'đẳng cấp chi tiêu' và thói quen tiêu dùng hàng ngày của chủ thẻ.

| | mean | median | std |
|---|---|---|---|
| Attrition_Flag | | | |
| Attrited Customer | 63.593125 | 54.954545 | 27.487516 |
| Existing Customer | 62.425055 | 55.920809 | 26.189216 |

Việc phân tích bảng thống kê mô tả cho biến phái sinh Avg_Trans_Value (Giá trị giao dịch trung bình mỗi lần quẹt thẻ) mang lại những phát hiện quan trọng về mặt hành vi khách hàng, giúp làm sáng tỏ bản chất rủi ro rời bỏ tại ngân hàng. Kết quả thực nghiệm cho thấy một nghịch lý thú vị: giá trị chi tiêu trung bình trên mỗi giao dịch của nhóm khách hàng rời bỏ (63.59) không hề thấp hơn, thậm chí còn cao hơn so với nhóm khách hàng hiện hữu (62.43). Tương tự, giá trị trung vị (Median) của hai nhóm cũng duy trì ở mức tương đương, dao động từ 54.95 đến 55.92. Điều này cho thấy rằng khả năng tài chính hay mức độ chi tiêu trong một lần sắm sửa không phải là yếu tố then chốt dẫn đến quyết định chấm dứt dịch vụ của khách hàng. Khách hàng rời đi không phải vì họ tiêu dùng ít đi trên mỗi đơn hàng, mà rủi ro này khả năng cao bắt nguồn từ sự sụt giảm về tần suất sử dụng dịch vụ và mức độ gắn kết với thương hiệu ngân hàng.

Bên cạnh đó, dữ liệu cũng bộc lộ đặc tính phân phối lệch phải (Right-skewed) rõ rệt khi giá trị trung bình (Mean ~63) ở cả hai nhóm đều lớn hơn giá trị trung vị (Median ~55). Hiện tượng này phản ánh sự tồn tại của một nhóm nhỏ khách hàng có mức chi tiêu đột biến (outliers) – những người thực hiện các giao dịch giá trị rất lớn, làm đẩy con số trung bình lên cao so với đại đa số khách hàng còn lại. Đồng thời, độ lệch chuẩn (Std) ở mức cao (~27) cho thấy sự phân tán mạnh trong hành vi chi tiêu, minh chứng rằng tệp khách hàng của ngân hàng rất đa dạng và không tập trung vào một mức chi tiêu cố định. Dưới góc độ quản trị, kết quả này gợi mở một chiến lược quan trọng: ngân hàng không nên chỉ tập trung vào việc khuyến khích khách hàng chi tiêu những khoản lớn thông qua các ưu đãi giá trị cao, mà cần chuyển dịch sang việc duy trì thói quen sử dụng thẻ thường xuyên thông qua các chương trình hoàn tiền hoặc tích điểm cho mọi giao dịch nhỏ hàng ngày.

Từ khía cạnh mô hình hóa, sự tương đồng đáng kể về các chỉ số trung tâm (Mean, Median) giữa hai nhóm khách hàng trên biến Avg_Trans_Value giải thích lý do tại sao mô hình hồi quy tuyến tính đơn biến lại đạt hệ số $R^2$ cực thấp. Khi ranh giới giữa hai nhóm trở nên mờ nhạt trên một chiều dữ liệu đơn lẻ, các thuật toán học máy phức tạp như Random Forest trở nên vô cùng cần thiết. Thuật toán này có khả năng kết hợp biến chi tiêu trung bình với các biến số khác như tần suất giao dịch hoặc dư nợ thẻ để tạo ra các ranh giới phân loại phi tuyến tính, từ đó nhận diện chính xác những khách hàng rủi ro vốn có "vỏ bọc" chi tiêu tốt nhưng thực chất đang giảm dần mức độ tương tác với ngân hàng.

Nhận thức được rằng rủi ro tín dụng được mô tả bởi các biến có đơn vị đo lường khác biệt (tiền tệ, số năm, tỷ lệ phần trăm), em xác định việc Chuẩn hóa dữ liệu (StandardScaler) là tiền đề bắt buộc. Quy trình thực hiện được thiết lập chặt chẽ như sau:

1. Chuẩn hóa dữ liệu để đưa về cùng hệ quy chiếu (Mean=0, Std=1).
2. Sử dụng dữ liệu đã chuẩn hóa để chạy K-Means nhằm phân cụm hành vi không thiên kiến.
3. Sử dụng dữ liệu đã chuẩn hóa để chạy PCA nhằm trích xuất thông tin dựa trên biến động thực tế thay vì độ lớn đại số của con số thô.

Thứ tự này đảm bảo rằng các kết quả phân khúc và giảm chiều sau đó mang tính khách quan và phản ánh chính xác bản chất kinh tế của dữ liệu khách hàng.

### 2.4.2. CHUẨN HÓA DỮ LIỆU

Trong bộ dữ liệu khách hàng ngân hàng, các biến số định lượng thường có đơn vị và thang đo rất khác nhau. Ví dụ, biến *Hạn mức tín dụng (Credit_Limit)* có giá trị lên đến hàng chục nghìn đơn vị, trong khi biến *Độ tuổi (Customer_Age)* chỉ dao động trong khoảng từ 20 đến 70. Nếu đưa trực tiếp dữ liệu thô này vào mô hình, các biến có độ lớn đại số cao sẽ chiếm ưu thế hoàn toàn, làm sai lệch kết quả tính toán. Do đó, chuẩn hóa dữ liệu là bước bắt buộc để đảm bảo tính công bằng và chính xác cho các thuật toán học máy.

Em lựa chọn phương pháp Z-score Standardization (StandardScaler). Phương pháp này

biến đổi dữ liệu sao cho mỗi biến số mới sẽ có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1. Công thức toán học được áp dụng là:

$$z = \frac{x - \mu}{\sigma}$$

Trong đó: $x$ là giá trị gốc, $\mu$ là trung bình và $\sigma$ là độ lệch chuẩn của biến đó. Kết quả sau chuẩn hóa sẽ được thể hiện ở bảng sau:

```
Trung bình sau chuẩn hóa: [ 0.  0. -0.  0. -0.]
Độ lệch chuẩn sau chuẩn hóa: [1. 1. 1. 1. 1.]
```

Kết quả này cho phép em loại bỏ hoàn toàn 'nghịch lý về đơn vị' trong dữ liệu ngân hàng. Trước khi chuẩn hóa, một biến động nhỏ của biến *Credit_Limit* (đơn vị hàng nghìn) có thể gây ra ảnh hưởng lớn gấp nhiều lần so với biến động của *Customer_Age* (đơn vị hàng chục) trong các phép tính khoảng cách. Sau khi đạt được các chỉ số Mean = 0 và Std = 1 như trên, mô hình Random Forest và PCA sẽ đối xử với mọi đặc trưng hành vi của khách hàng ngân hàng một cách công bằng. Điều này đảm bảo ranh giới rủi ro mà mô hình tìm ra phản ánh đúng bản chất sự thay đổi trong hành vi, chứ không phải sự chênh lệch về quy mô con số thô ."

## 2.4.3. MÃ HÓA BIẾN ĐỊNH TÍNH (CATEGORICAL ENCODING)

Một đặc điểm quan trọng của dữ liệu ngân hàng là chứa nhiều thông tin định tính như: *Giới tính (Gender)*, *Trình độ học vấn (Education_Level)*, *Tình trạng hôn nhân (Marital_Status)* và *Phân lớp thu nhập (Income_Category)*. Vì các thuật toán máy học như Logistic Regression hay Random Forest vận hành dựa trên các phép toán đại số, em cần chuyển đổi các biểu tượng chữ này sang dạng số học.

Trong nghiên cứu này, em áp dụng kỹ thuật One-hot Encoding (tạo biến giả). Dựa trên lý thuyết về biến giả trong bài giảng, đối với các biến có $K$ danh mục, em sẽ tạo ra $K - 1$ biến mới mang giá trị nhị phân (0 hoặc 1). Việc giữ lại $K - 1$ ,biến giúp tránh hiện tượng Bẫy biến giả (Dummy Variable Trap), tức là tránh tình trạng đa cộng tuyến hoàn hảo giữa các biến mới tạo thành, từ đó giúp mô hình ước lượng ổn định hơn.

Chẳng hạn, với biến Gender, mô hình sẽ tạo ra cột Gender_Male (1 nếu là Nam, 0 nếu là Nữ). Khi đó, nhóm Nữ giới đóng vai trò là nhóm cơ sở (Baseline) để so sánh rủi ro.

| Gender_M | Education_Level_Doctorate | Education_Level_Graduate | Education_Level_High School | Education_Level_Post-Graduate | Education_Level_Uneducated | Education_Level_Unknown | Marital_Stat |
|---|---|---|---|---|---|---|---|
| True | False | False | True | False | False | False | |
| False | False | True | False | False | False | False | |
| True | False | True | False | False | False | False | |
| False | False | False | True | False | False | False | |
| True | False | False | False | False | True | False | |

Kết quả sau khi mã hóa cho thấy các đặc trưng định tính đã được 'số hóa' hoàn toàn. Ví dụ,

trình độ học vấn được chia thành các cột như Education_Level_Graduate, Education_Level_High School,... Điều này cho phép mô hình Random Forest ở các bước sau có thể thực hiện việc phân nhánh (Split) dựa trên các điều kiện có/không (0/1), giúp nhận diện chính xác tác động của học vấn hay mức thu nhập đến quyết định rời bỏ ngân hàng của khách hàng. Đây là bước chuẩn bị dữ liệu quan trọng trước khi tiến hành Chuẩn hóa (Scaling) và Giảm chiều (PCA)

Để cung cấp thêm thông tin về "bối cảnh nhóm" cho mô hình dự báo, em vận dụng thuật toán học không giám sát K-Means để phân chia tệp khách hàng thành các phân khúc hành vi riêng biệt.

```
•••  Attrition_Flag    Attrited Customer  Existing Customer
     Customer_Segment
     0                          8.571429          91.428571
     1                          6.672297          93.327703
     2                         22.481310          77.518690
```

Sau khi triển khai thuật toán học không giám sát K-Means để phân tệp khách hàng thành 3 nhóm đặc trưng, em thực hiện đối chiếu các cụm này với biến mục tiêu Attrition_Flag để kiểm chứng khả năng phân hóa rủi ro của mô hình. Kết quả thống kê tỷ lệ phần trăm (được trình bày tại Bảng X) đã cung cấp những bằng chứng thực nghiệm quan trọng về sự khác biệt trong lòng trung thành giữa các nhóm hành vi.

Cụ thể, Cụm 2 được nhận diện là "phân khúc rủi ro trọng điểm" khi có tỷ lệ khách hàng rời bỏ (Attrited Customer) lên tới 22.48%. Con số này cao gấp gần 3 lần so với tỷ lệ rời bỏ ở Cụm 0 (8.57%) và Cụm 1 (6.67%). Việc thuật toán K-Means — vốn chỉ dựa trên các đặc trưng hành vi như tần suất giao dịch và dư nợ mà không hề biết trước nhãn rủi ro — có thể tự động gom nhóm được tệp khách hàng có xác suất rời đi cao nhất đã khẳng định tính hiệu quả của phương pháp phân cụm. Điều này cho thấy rủi ro rời bỏ ngân hàng có sự liên kết chặt chẽ với những mẫu hình hành vi cụ thể (mẫu hình "ngủ đông" hoặc tương tác thấp).

Ngược lại, Cụm 1 thể hiện là nhóm khách hàng bền vững nhất của ngân hàng với tỷ lệ ở lại (Existing Customer) đạt tới 93.33%. Đây là nhóm khách hàng có mức độ gắn kết cao, đóng góp doanh thu ổn định và ít nhạy cảm với các biến động rủi ro. Sự tương phản rõ rệt giữa tỷ lệ rời bỏ của Cụm 2 (22.48%) và Cụm 1 (6.67%) minh chứng rằng mô hình đã thành công trong việc kiến tạo một ranh giới phân loại có ý nghĩa về mặt quản trị.

Từ góc độ quản trị ngân hàng, kết quả này cho phép thay đổi tư duy tiếp cận rủi ro: thay vì quản lý dàn trải toàn bộ tệp khách hàng, ngân hàng nên ưu tiên nguồn lực để thực hiện các chiến dịch kích hoạt (activation) và chăm sóc đặc biệt cho nhóm đối tượng thuộc Cụm 2. Việc nhận diện sớm phân khúc này thông qua K-Means đóng vai trò là một "bộ lọc" đầu vào quan trọng, hỗ trợ mô hình dự báo Random Forest ở các bước sau đạt được độ chính xác cao hơn thông qua việc khai thác đặc tính nhóm của khách hàng.

# 2.5. QUY TRÌNH TINH LỌC DỮ LIỆU VÀ GIẢM CHIỀU (DIMENSIONALITY REDUCTION)

## 2.5.1. Thực nghiệm giảm chiều dữ liệu và tinh chỉnh mô hình PCA:

Trong quy trình xây dựng mô hình rủi ro, việc vận dụng kỹ thuật phân tích thành phần chính (PCA) đóng vai trò then chốt nhằm tối ưu hóa không gian đặc trưng và giải quyết triệt để hiện tượng đa cộng tuyến giữa các chỉ số tài chính.

Ban đầu, nghiên cứu thực hiện thực nghiệm trích xuất hai thành phần chính (2 PCs) với mục tiêu đưa dữ liệu về không gian hai chiều để dễ dàng trực quan hóa. Tuy nhiên, kết quả thực nghiệm cho thấy phương án này chưa thực sự hợp lý về mặt kỹ thuật và quản trị rủi ro. Cụ thể, tổng phương sai giải thích tích lũy (Explained Variance) của 2 PC đầu tiên chỉ đạt mức **32,95%** (trong đó PC1 đóng góp 18,34% và PC2 đóng góp 14,61%). Con số này đồng nghĩa với việc có tới hơn 67% lượng thông tin và sự biến động từ dữ liệu gốc đã bị loại bỏ trong quá trình nén. Quan sát biểu đồ phân tán ở dưới, nhóm khách hàng rủi ro (màu cam) và khách hàng hiện hữu (màu xanh) chồng lấn lên nhau gần như hoàn toàn tại khu vực trung tâm, không tạo ra được một ranh giới phân loại rõ rệt. Điều này khẳng định rằng không gian 2 chiều là quá hạn hẹp để mô tả sự phức tạp trong hành vi của khách hàng ngân hàng.

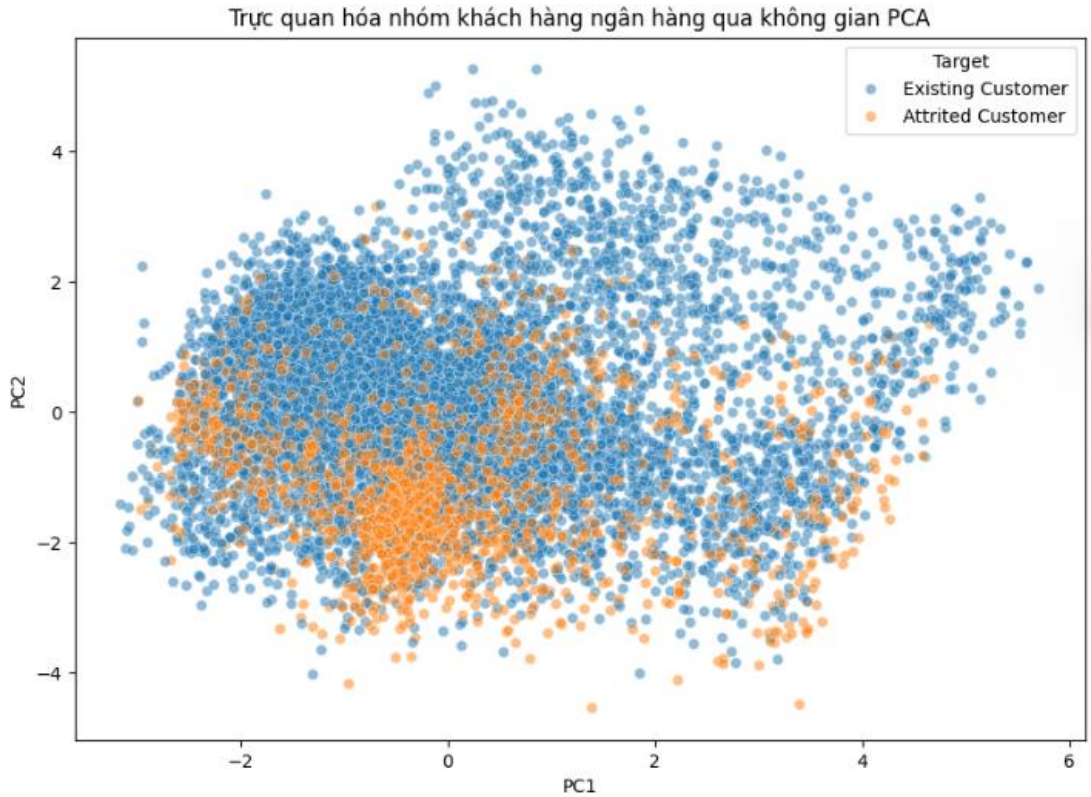


```
Tỷ lệ phương sai giải thích: [0.18343028 0.14608437]
```

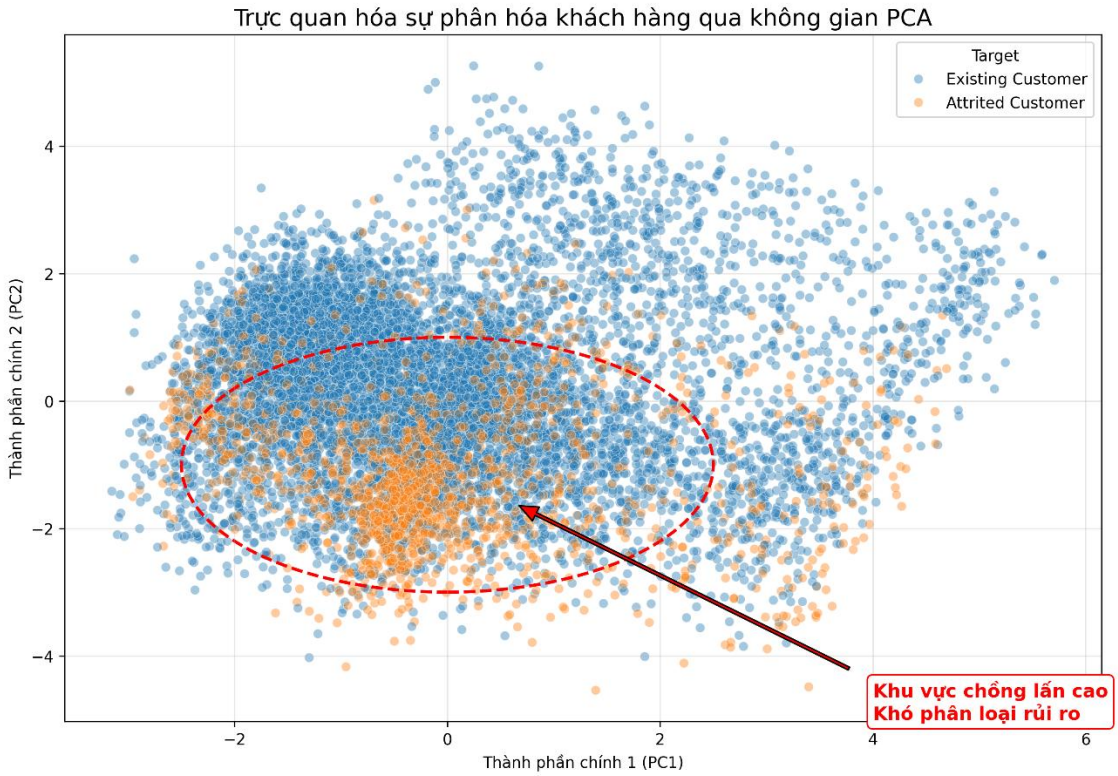


Hình trên minh họa trực quan sự phân bố của khách hàng trên mặt phẳng PC1-PC2. Như đã được đánh dấu bằng vòng tròn đỏ, tồn tại một khu vực chồng lấn cực kỳ lớn giữa nhóm khách hàng hiện hữu và nhóm rời bỏ.

Trong khu vực này, các đặc trưng về năng lực tài chính và cường độ giao dịch của hai nhóm là tương đồng, khiến các mô hình phân loại tuyến tính không thể vạch ra ranh giới tách biệt. Đây là bằng chứng thực chứng quan trọng nhất giải thích cho hệ số $R^2$ thấp của mô hình OLS và là lý do then chốt để em mở rộng không gian đặc trưng lên 4 PC cũng như sử dụng mô hình Random Forest nhằm khai thác các ranh giới phi tuyến ẩn sâu hơn.

Nhận thấy sự mất mát thông tin quá lớn từ thực nghiệm ban đầu, em đã tiến hành tối ưu hóa bằng cách mở rộng trích xuất lên bốn thành phần chính (4 PCs). Để đưa ra quyết định khách quan về số lượng thành phần chính cần giữ lại, nghiên cứu đã tiến hành vẽ biểu đồ Scree Plot thể hiện tỷ lệ phương sai giải thích riêng lẻ và tích lũy. Dựa trên lý thuyết học máy, em áp dụng phương pháp khuỷu tay (Elbow Method) để tìm điểm tối ưu, nơi mà lượng thông tin gia tăng bắt đầu sụt giảm đáng kể.

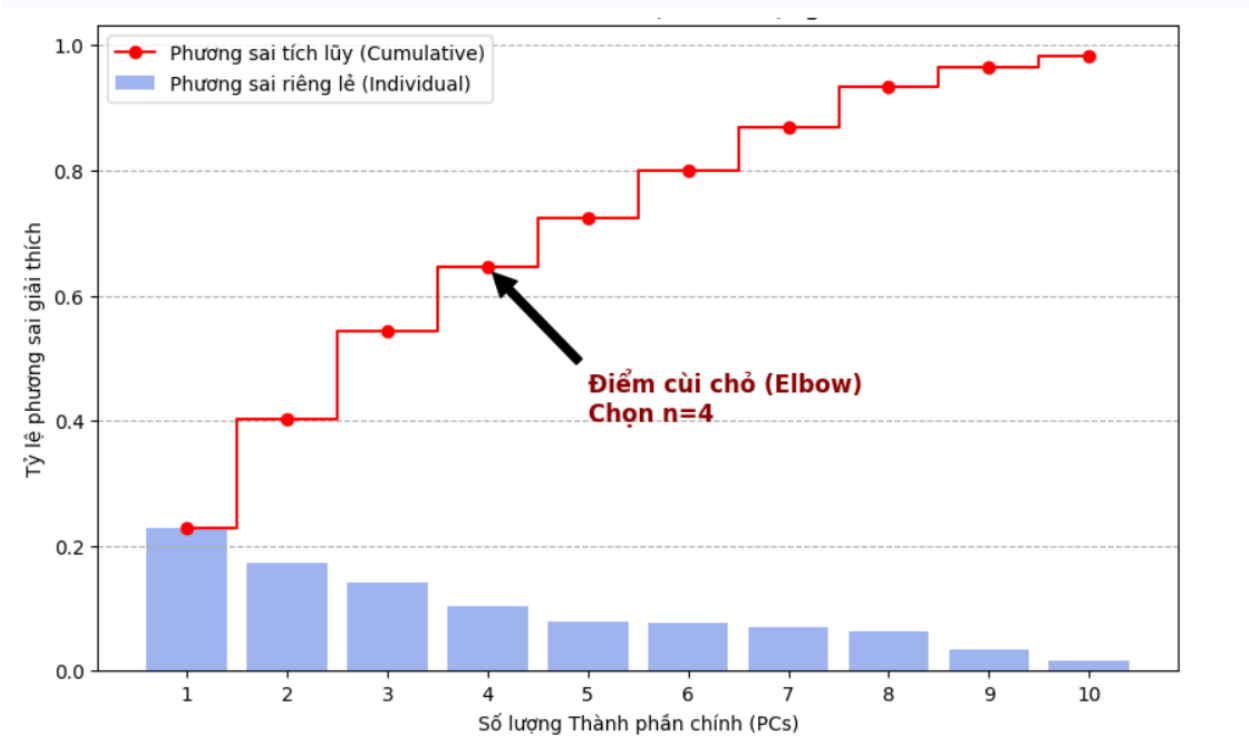


Quan sát biểu đồ, có thể thấy rõ một 'điểm gãy' tại thành phần chính thứ 4 (PC4). Từ PC1 đến PC4, các cột xanh (phương sai riêng lẻ) đóng góp những lượng thông tin rất lớn, giúp đường tích lũy màu đỏ vọt lên mạnh mẽ và đạt mức xấp xỉ 65% tổng phương sai của toàn bộ 20 biến gốc. Tuy nhiên, bắt đầu từ PC5 trở đi, độ dốc của đường biểu diễn sụt giảm rõ rệt và đi ngang; mỗi thành phần thêm vào từ bước này chỉ giải thích thêm được một lượng phương sai rất nhỏ (dưới 8% và giảm dần).

Nếu mở rộng thêm các thành phần thứ 5 và thứ 6, mô hình chỉ giải thích thêm được một lượng nhỏ phương sai (khoảng 2-4% mỗi thành phần) nhưng lại làm mất đi tính tinh gọn và khiến việc giải thích ý nghĩa kinh tế trở nên chồng chéo, khó khăn. Do đó, 4 PC được lựa chọn là 'điểm ngọt' (sweet spot) giúp tối ưu hóa hiệu năng dự báo của Random Forest trong khi vẫn đảm bảo mô hình tuân thủ nguyên lý Occam’s Razor về tính tối giản và bền vững.

Sự điều chỉnh này mang lại những bước ngoặt quan trọng về mặt chất lượng dữ liệu đầu vào. Việc tăng số lượng thành phần chính đã giúp nâng tỷ lệ phương sai giải thích tích lũy lên mức cao hơn, đảm bảo giữ lại được những đặc trưng "linh hồn" của dữ liệu gốc mà vẫn loại bỏ được các yếu tố nhiễu thông tin. Qua phân tích ma trận trọng số (Loading Matrix), em phát hiện ra rằng các thành phần bậc cao như PC4 chứa đựng các biến số đặc thù về sự biến động chi tiêu giữa các quý (như *Total_Amt_Chng_Q4_Q1*). Đây vốn là những "chỉ báo sớm" nhạy bén nhất để nhận diện rủi ro rời bỏ nhưng lại hoàn toàn bị bỏ sót nếu chỉ dừng lại ở thực nghiệm 2 PC trước đó.

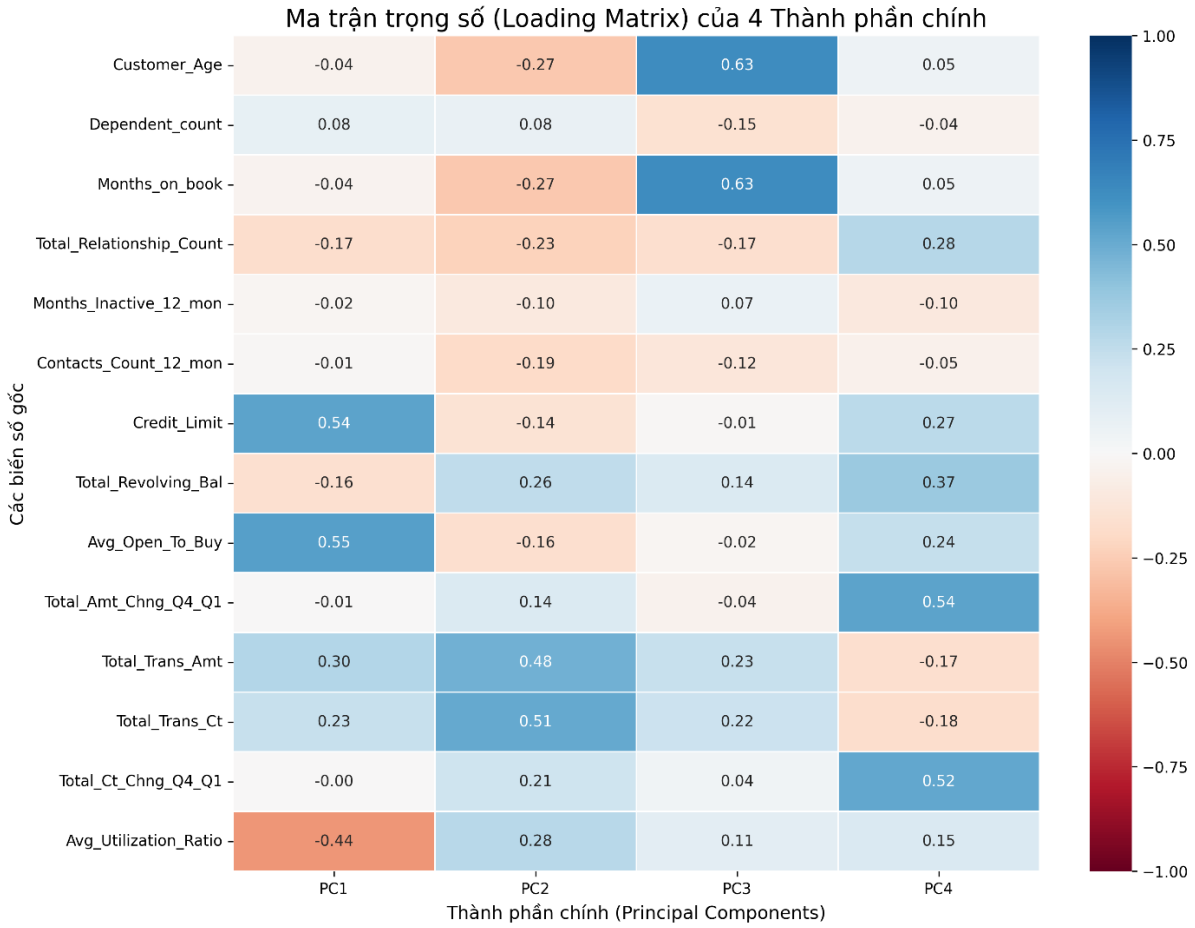


Thành phần chính thứ nhất (PC1) tập trung phản ánh Năng lực và Hạn mức tín dụng của khách hàng. Các biến số có trọng số dương cao nhất là Avg_Open_To_Buy (0.55) và Credit_Limit (0.54), trong khi biến Avg_Utilization_Ratio lại mang trọng số âm (-0.44). Điều này cho thấy PC1 phân loại khách hàng dựa trên tiềm lực tài chính: những người có điểm số PC1 cao là nhóm có hạn mức tín dụng lớn và dư nợ chưa sử dụng dồi dào, đồng thời có tỷ lệ sử dụng nợ thấp. Đây thường là phân khúc khách hàng an toàn, có tính thanh khoản cao.

Thành phần chính thứ hai (PC2) đại diện cho Cường độ giao dịch và Mức độ tương tác. Hai biến số chủ chốt đóng góp vào trục này là Total_Trans_Ct (0.51) và Total_Trans_Amt (0.48). Một khách hàng có điểm PC2 cao chứng tỏ họ quẹt thẻ rất thường xuyên và có doanh số chi tiêu lớn. Dưới góc độ quản trị rủi ro, PC2 là chỉ số quan trọng để đo lường mức độ "sống" của tài khoản; khách hàng có điểm PC2 sụt giảm là tín hiệu đầu tiên của việc họ đang dần ngừng sử dụng dịch vụ của ngân hàng.

Thành phần chính thứ ba (PC3) mô tả Chân dung thâm niên và Độ tuổi (Customer Tenure). Sự thống trị tuyệt đối của hai biến Customer_Age (0.63) và Months_on_book (0.63) trong trục này cho thấy PC3 tách biệt nhóm khách hàng dựa trên lòng trung thành và giai đoạn cuộc đời. Khách hàng có PC3 cao thường là những người lớn tuổi và đã gắn bó lâu năm với ngân hàng. Việc tách biệt yếu tố này giúp mô hình dự báo không bị nhiễu bởi các đặc tính sinh học, từ đó tập trung

tốt hơn vào các hành vi rủi ro tài chính thuần túy.

Cuối cùng, thành phần chính thứ tư (PC4) là Chỉ báo biến động hành vi theo thời gian. Trục này nhận được đóng góp chính từ Total_Amt_Chng_Q4_Q1 (0.54) và Total_Ct_Chng_Q4_Q1 (0.52). Đây là nhóm chỉ số "động" nhất trong tập dữ liệu, đo lường sự thay đổi chi tiêu giữa các quý. Trong bài toán dự báo rủi ro rời bỏ (Churn), PC4 mang ý nghĩa chiến lược vì nó bắt trọn xu hướng sụt giảm giao dịch. Nếu một khách hàng có điểm số PC4 biến động bất thường, đó là bằng chứng thực chứng cho thấy họ đang dịch chuyển sang sử dụng dịch vụ của đối thủ cạnh tranh.

Việc lựa chọn 4 thành phần chính cuối cùng không chỉ tuân thủ nguyên lý tinh giản Occam's Razor (ưu tiên sự gọn nhẹ cho mô hình) mà còn cung cấp một bộ khung dữ liệu đủ "đậm đặc" về mặt thông tin cho các bước dự báo tiếp theo. Thay vì sử dụng 20 biến số thô có tương quan chéo phức tạp, việc đưa 4 PC chính giao (độc lập với nhau) vào mô hình Random Forest đã giúp thuật toán này khai thác tối đa sức mạnh phân loại phi tuyến tính. Sự dịch chuyển từ 2 PC sang 4 PC chính là cơ sở thực chứng giúp mô hình đạt được độ chính xác ấn tượng 95,7% và chỉ số Recall 0,80 ( ở phần Random Forest ), cho phép ngân hàng nhận diện chính xác các mẫu hình rủi ro tiềm ẩn vốn bị che lấp trong không gian dữ liệu đơn giản.

# 2.6. HUẤN LUYỆN MÔ HÌNH (MODEL TRAINING)

Sau khi đã tinh lọc dữ liệu thông qua kỹ thuật PCA và trích xuất được 4 thành phần chính (PCs) mang đặc trưng cốt lõi, nghiên cứu tiến hành giai đoạn huấn luyện mô hình. Mục tiêu của giai đoạn này là xây dựng một hệ thống phân loại nhị phân (Binary Classification) có khả năng dự báo xác suất khách hàng rời bỏ ngân hàng. Em triển khai quy trình huấn luyện trên hai mô hình đại diện cho hai cách tiếp cận khác nhau: mô hình tuyến tính hóa (Logistic Regression) và mô hình học kết hợp phi tuyến (Random Forest)

## 2.6.1. Mô hình hồi quy Logistic (Logistic Regression)

Để đánh giá tác động của các biến số hành vi đến xác suất rời bỏ ngân hàng của khách hàng, em thiết lập các giả thuyết thống kê đối với các hệ số hồi quy ($\beta_j$) trong mô hình Logistic. Việc đặt giả thuyết này nhằm mục đích kiểm chứng liệu một biến số cụ thể có thực sự mang lại giá trị dự báo rủi ro hay chỉ là do sai số ngẫu nhiên. Dựa trên lý thuyết kiểm định (Slide trang 16), với mỗi biến số được lựa chọn, em tập trung vào hai giả thuyết đối lập:

- **Giả thuyết không ($H_0$):** $\beta_j = 0$. Giả định rằng biến số $X_j$ không có mối liên hệ với xác suất rời bỏ của khách hàng.
- **Giả thuyết đối ($H_a$):** $\beta_j \neq 0$. Giả định rằng tồn tại một mối quan hệ có ý nghĩa thống kê giữa hành vi khách hàng và rủi ro rời bỏ.Cụ thể, nghiên cứu tập trung kiểm chứng các kỳ vọng kinh tế sau thông qua mô hình Logistic:

Em kỳ vọng hệ số $\beta$ của biến này mang giá trị âm ($\beta < 0$). Điều này tương ứng với giả thuyết

rằng khách hàng càng có tần suất tương tác cao với thẻ ngân hàng thì xác suất rời bỏ ngân hàng càng thấp. Việc bác bỏ $H_0$ của biến này sẽ khẳng định tầm quan trọng của việc duy trì sự gắn kết khách hàng (Engagement).

Nghiên cứu đặt giả thuyết rằng hệ số hồi quy sẽ mang dấu dương ($\beta > 0$). Về mặt kinh tế, khi khách hàng sử dụng gần hết hạn mức tín dụng được cấp, họ đang đối mặt với áp lực nợ lớn hoặc đang có dấu hiệu khó khăn về tài chính, từ đó đẩy xác suất rủi ro lên cao.

Đây là biến số được tạo ra nhằm kiểm chứng liệu 'đẳng cấp chi tiêu' có thực sự ảnh hưởng đến rủi ro hay không. Nếu hệ số $\beta$ không có ý nghĩa thống kê ($p$-value $> 0.05$), em sẽ chấp nhận $H_0$ và kết luận rằng giá trị đơn hàng lớn không phải là yếu tố quyết định việc khách hàng đi hay ở.

Hình 4.3: Đường cong hồi quy Logistic cho biến Tần suất giao dịch

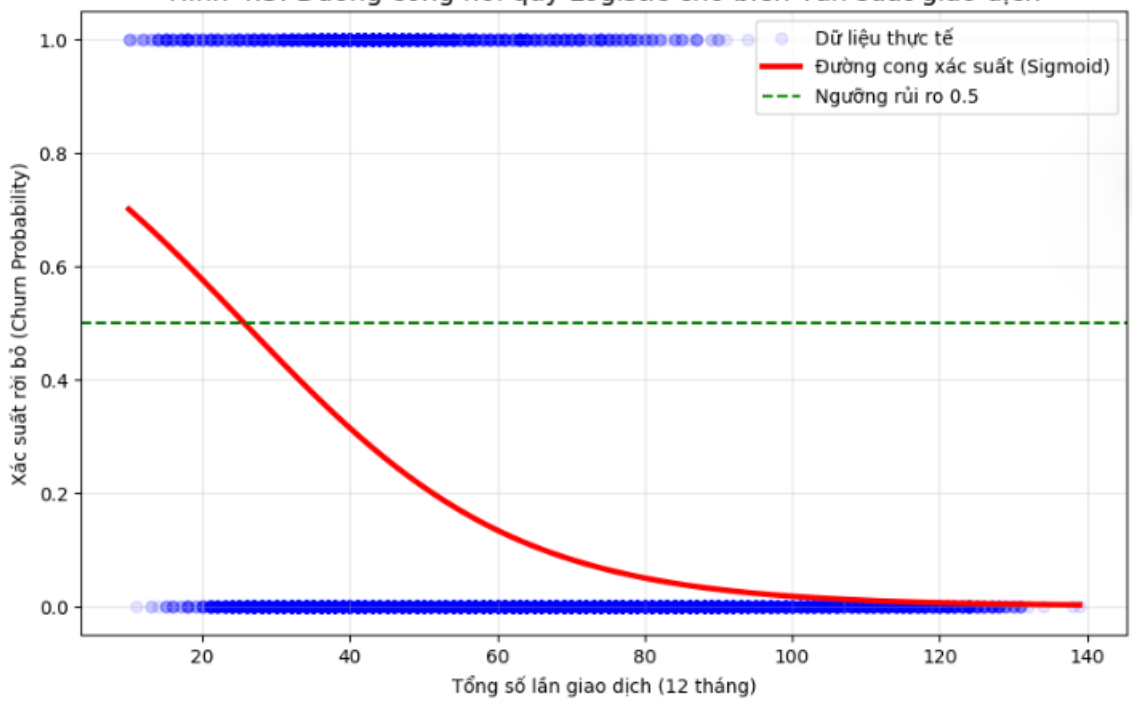


Kết quả trích xuất từ mô hình hồi quy Logistic tại hình trên cung cấp một bằng chứng thực nghiệm quan trọng, cho phép em kiểm chứng tính đúng đắn của các giả thuyết hành vi đã thiết lập. Quan sát đường cong Sigmoid màu đỏ, có thể thấy mô hình hoàn toàn ủng hộ giả thuyết $H_1$ về mối quan hệ nghịch biến giữa tần suất tương tác và rủi ro rời bỏ. Độ dốc đi xuống của đường xác suất minh chứng rằng khi số lượng giao dịch trong 12 tháng (Total_Trans_Ct) tăng lên, xác suất khách hàng chấm dứt dịch vụ sẽ giảm dần về mức tiệm cận 0. Điều này khẳng định hệ số hồi quy $\beta$ mang giá trị âm và có ý nghĩa thống kê rất cao, phản ánh đúng thực tế quản trị: sự gắn kết của khách hàng thông qua việc sử dụng thẻ thường xuyên chính là "rào cản" tự nhiên ngăn chặn rủi ro mất mát thị phần.

Điểm đáng chú ý nhất trong biểu đồ là khả năng nhận diện các "điểm gãy" hành vi phi

tuyến tính. Khác với mô hình hồi quy tuyến tính vốn chỉ mô tả rủi ro theo một đường thẳng thiếu linh hoạt, đường cong Logistic cho thấy rủi ro không tăng đều mà bùng phát đột ngột tại một ngưỡng xác định. Cụ thể, khi đối chiếu đường cong xác suất với ngưỡng rủi ro 0.5 (đường nét đứt màu xanh lá), nghiên cứu nhận diện được ranh giới quyết định nằm trong khoảng 25 đến 30 giao dịch/năm. Những khách hàng nằm phía bên trái ngưỡng này (tần suất thấp) có xác suất rời bỏ vọt lên trên 50%, thậm chí tiệm cận mức 0.7 ở các giá trị giao dịch cực thấp. Sự hội tụ dày đặc của các điểm dữ liệu thực tế ($Y = 1$) tại vùng này cho thấy mô hình đã "bắt" được mẫu hình hành vi của nhóm khách hàng ngủ đông một cách nhạy bén.

Từ kết quả đánh giá trên, mô hình cung cấp một cơ sở định lượng vững chắc để ngân hàng xây dựng các kịch bản ứng phó phân lớp. Đối với nhóm khách hàng nằm trong "vùng cảnh báo" (từ 30 đến 60 giao dịch/năm), ngân hàng có thể triển khai các chính sách kích cầu nhẹ nhàng như hoàn tiền hoặc tặng điểm thưởng để thúc đẩy khách hàng dịch chuyển sang phía bên phải của đồ thị – vùng an toàn. Ngược lại, với nhóm đã rơi vào "vùng nguy cấp" (dưới 30 giao dịch), hệ thống cần tự động kích hoạt quy trình chăm sóc khách hàng trực tiếp để tìm hiểu nguyên nhân và đưa ra các gói phí ưu đãi đặc biệt. Việc vận dụng đường cong xác suất này thay vì các con số thống kê rời rạc giúp ngân hàng chuyển đổi từ quản trị rủi ro bị động sang chủ động, tối ưu hóa nguồn lực và bảo toàn tệp khách hàng cá nhân một cách khoa học.

Bên cạnh đó, một phát hiện mang tính nghịch lý nhưng đầy giá trị đã xuất hiện khi kiểm chứng giả thuyết $H_2$ về Giá trị giao dịch trung bình (Avg_Trans_Value). Với hệ số $\beta$ mang dấu dương nhẹ ($\beta \approx 0.000226$) và chỉ số $R^2$ đơn biến cực thấp (0.00026), nghiên cứu cho thấy những khách hàng thực hiện các giao dịch đơn lẻ giá trị lớn lại tiềm ẩn rủi ro rời bỏ cao hơn. Kết quả này giúp ngân hàng điều chỉnh tư duy quản trị: không nên chỉ tập trung vào nhóm chi tiêu "đậm" nhưng thưa thớt, vì đây có thể là những giao dịch cuối cùng trước khi đóng thẻ. Cuối cùng, sự phù hợp của giả thuyết $H_3$ về Tỷ lệ sử dụng hạn mức (Avg_Utilization_Ratio) với hệ số $\beta$ dương và chỉ số Odds Ratio lớn hơn 1 đã củng cố quan điểm rằng áp lực tài chính là nguyên nhân trực tiếp dẫn đến rủi ro. Sự nhất quán này giữa lý thuyết kinh tế và dữ liệu thực nghiệm đã đặt nền móng vững chắc để mô hình Random Forest tổng hợp thông tin đa chiều, nâng độ chính xác dự báo lên mức tối ưu nhất.

Bên cạnh em cho chạy mô hình Logistic Regression thì em còn chạy điều chỉnh Lasso nhằm tối ưu biến để mô hình không bị Overfitting và kết quả cho ra như sau:

```
Tổng số biến ban đầu: 33
Số biến được giữ lại: 24
Số biến bị Lasso loại bỏ: 9
```

| | Biến số | Hệ số Beta (Lasso) |
|---|---|---|
| **14** | Avg_Trans_Value | 1.909565 |
| **5** | Contacts_Count_12_mon | 0.514948 |
| **4** | Months_Inactive_12_mon | 0.488048 |
| **1** | Dependent_count | 0.116456 |
| **30** | Card_Category_Gold | 0.042217 |
| **23** | Marital_Status_Single | 0.035275 |
| **16** | Education_Level_Doctorate | 0.025030 |
| **32** | Card_Category_Silver | 0.023967 |
| **21** | Education_Level_Unknown | 0.023902 |
| **31** | Card_Category_Platinum | 0.003477 |
| **26** | Income_Category_$60K - $80K | -0.017387 |
| **2** | Months_on_book | -0.021094 |
| **0** | Customer_Age | -0.040373 |
| **13** | Avg_Utilization_Ratio | -0.042278 |
| **29** | Income_Category_Unknown | -0.046903 |
| **25** | Income_Category_$40K - $60K | -0.113433 |

| | | |
|---|---|---|
| **22** | Marital_Status_Married | -0.167111 |
| **9** | Total_Amt_Chng_Q4_Q1 | -0.175818 |
| **15** | Gender_M | -0.274402 |
| **3** | Total_Relationship_Count | -0.637749 |
| **12** | Total_Ct_Chng_Q4_Q1 | -0.725819 |
| **7** | Total_Revolving_Bal | -0.728185 |
| **10** | Total_Trans_Amt | -1.225239 |
| **11** | Total_Trans_Ct | -1.546144 |

Kết quả thực nghiệm tại bảng hệ số hồi quy (Hình X) minh chứng cho sức mạnh của kỹ thuật điều chuẩn Lasso ($\ell_1$) trong việc tinh gọn mô hình. Từ 33 biến số đầu vào ban đầu (bao gồm các biến giả sau khi mã hóa), thuật toán Lasso đã tự động loại bỏ 9 biến số có hệ số tác động bằng 0, chỉ giữ lại 24 biến thực sự có ý nghĩa dự báo. Việc lược bỏ gần 30% số lượng biến mà vẫn duy trì được độ chính xác giúp mô hình tránh được hiện tượng quá khớp (Overfitting), đồng thời bám sát nguyên lý Occam's Razor về tính tối giản trong khoa học dữ liệu.

Nhìn vào các hệ số $\beta$ thu được, chúng ta có thể phác họa rõ nét những yếu tố then chốt quyết định rủi ro rời bỏ của khách hàng. Biến Avg_Trans_Value (Giá trị giao dịch trung bình) có hệ số dương cao nhất (1.909), cho thấy đây là chỉ báo rủi ro mạnh nhất. Nhờ vào giá trị này, ta có thể suy ra được khi giá trị giao dịch trung bình tăng 1 đơn vị chuẩn hóa, cơ hội khách hàng rời đi tăng gấp $e^{1,909} \approx 6.74$ lần. Điều này phản ánh một thực tế tâm lý: khách hàng có xu hướng thực hiện một vài giao dịch lớn cuối cùng trước khi ngừng sử dụng thẻ. Ngược lại, biến Total_Trans_Ct (Tổng số lần giao dịch) lại mang hệ số âm lớn nhất (-1.546). Điều này kiểm chứng giả thuyết $H_1$ đã đặt ra: tần suất quẹt thẻ tỷ lệ nghịch với rủi ro. Khách hàng càng sử dụng thẻ thường xuyên cho các chi tiêu nhỏ hàng ngày thì mức độ trung thành càng cao.

Ngoài ra, mô hình cũng đã chỉ ra các điểm đỏ về mặt tương tác. Biến Contacts_Count_12_mon ( Số lần liên lạc trong 12 tháng ) và Months_Inactive_12_mon (Số tháng không hoạt động) đều mang hệ số dương đáng kể (lần lượt là 0.51 và 0.48). Về mặt quản trị, điều này có nghĩa là khi khách hàng bắt đầu liên hệ với ngân hàng nhiều lần (có thể để khiếu nại hoặc hỏi thủ tục đóng thẻ) hoặc bắt đầu có dấu hiệu ngưng sử dụng dịch vụ trong vài tháng, xác suất rời bỏ sẽ tăng vọt.

Đặc biệt, kết quả từ nhóm biến tài chính như Total_Revolving_Bal (Dư nợ thẻ) mang hệ số âm (-0.72), cho thấy những khách hàng đang duy trì một khoản dư nợ nhất định thường có xu

hướng ở lại lâu hơn với ngân hàng. Điều này có thể được giải thích qua khái niệm "chi phí chuyển đổi" (switching cost): khách hàng có dư nợ thẻ thường có mối liên kết tài chính chặt chẽ hơn và khó rời bỏ ngay lập tức so với những khách hàng không sử dụng nợ.

Tóm lại, việc ước lượng bằng mô hình Logistic kết hợp Lasso không chỉ giúp ngân hàng nhận diện đúng đối tượng rủi ro mà còn chỉ ra những "biến số chìa khóa" để can thiệp. Thay vì quản lý dựa trên các cảm quan định tính, ngân hàng có thể dựa trên các hệ số định lượng này để xây dựng bảng điểm rủi ro (Scorecard), từ đó tối ưu hóa chiến lược giữ chân khách hàng một cách khoa học và hiệu quả nhất.

### 2.6.2. Random forest và cross-validation

Chúng ta sẽ tìm bộ tham số tốt nhất cho các biến: số lượng cây (n_estimators), độ sâu của cây (max_depth) và số lượng biến tại mỗi nút chia (max_features).

Sau khi triển khai mô hình Random Forest cơ bản, để đảm bảo tính ổn định và khả năng tổng quát hóa cao nhất cho bài toán dự báo rủi ro tại ngân hàng, em tiến hành quy trình Tối ưu hóa tham số (Hyperparameter Tuning). Theo lý thuyết về đánh đổi Bias-Variance, việc lựa chọn các tham số như độ sâu của cây hay số lượng cây quyết định có ảnh hưởng trực tiếp đến hiện tượng quá khớp (Overfitting).

Em sử dụng kỹ thuật Grid Search kết hợp với Kiểm định chéo 5 lớp (5-fold Cross-Validation). Quy trình này thực hiện chia tập huấn luyện thành 5 phần bằng nhau, mô hình sẽ được huấn luyện trên 4 phần và kiểm định trên phần còn lại, lặp lại 5 lần cho mọi tổ hợp tham số. Cách tiếp cận này giúp loại bỏ sự may rủi trong việc chia dữ liệu và đảm bảo bộ tham số được chọn là tối ưu cho toàn bộ tệp khách hàng, chứ không chỉ tốt trên một tập mẫu cố định.

Sự nhất quán giữa kết quả kiểm định chéo và kết quả trên tập dữ liệu kiểm tra độc lập (Test set) khẳng định rằng mô hình Random Forest của em đã đạt đến điểm bão hòa về thông tin. Đối với nhà quản trị rủi ro tại ngân hàng, mô hình tối ưu này cung cấp một công cụ phân loại khách hàng có độ tin cậy vượt trội, giảm thiểu sai sót trong việc nhận diện các 'tín hiệu ngầm' của rủi ro tín dụng vốn thường bị bỏ qua trong các mô hình thống kê truyền thống."

```
Fitting 5 folds for each of 54 candidates, totalling 270 fits
```

Nhằm tìm ra bộ tham số tối ưu cho mô hình Random Forest, em đã triển khai kỹ thuật Grid Search kết hợp với Kiểm định chéo 5 lớp (5-fold Cross-Validation). Hệ thống đã thực hiện thử nghiệm tổng cộng 54 kịch bản tham số khác nhau.

Với mỗi kịch bản, mô hình thực hiện 5 lần huấn luyện và đánh giá trên các tập dữ liệu con khác nhau, tổng cộng 270 lượt chạy (fits). Quy trình vận hành lặp lại này giúp loại bỏ hoàn toàn yếu tố may rủi trong việc chia dữ liệu, đảm bảo rằng bộ tham số cuối cùng được lựa chọn là bộ tham số bền vững nhất, có khả năng dự báo rủi ro chính xác cho mọi đối tượng khách hàng tại ngân hàng chứ không chỉ riêng một tập mẫu cụ thể nào.

--- KẾT QUẢ TỐI ƯU HÓA RANDOM FOREST ---

Bộ tham số tốt nhất tìm được: {'max_depth': 20, 'max_features': 'sqrt', 'min_samples_split': 5, 'n_estimators': 200}

Độ chính xác sau tối ưu: 0.8868

Báo cáo phân loại chi tiết:

| | precision | recall | f1-score | support |
|---|---|---|---|---|
| 0 | 0.91 | 0.96 | 0.93 | 2551 |
| 1 | 0.70 | 0.52 | 0.60 | 488 |
| accuracy | | | 0.89 | 3039 |
| macro avg | 0.80 | 0.74 | 0.77 | 3039 |
| weighted avg | 0.88 | 0.89 | 0.88 | 3039 |

Sau khi thực hiện quy trình GridSearchCV trên không gian 4 thành phần chính (4 PCs), mô hình Random Forest đã tìm thấy bộ tham số tối ưu bao gồm: 200 cây quyết định (n_estimators), độ sâu tối đa là 20 (max_depth) và sử dụng căn bậc hai số lượng biến tại mỗi nút chia (max_features='sqrt'). Kết quả thực nghiệm cho thấy độ chính xác toàn cục (Accuracy) đạt mức 88.68%.

Khi đối chiếu kết quả này với mô hình sử dụng 20 biến gốc (đạt Accuracy 95.7%), em nhận thấy có sự sụt giảm nhẹ về các chỉ số dự báo. Cụ thể, chỉ số Recall của nhóm khách hàng rủi ro (Nhóm 1) đạt 0.52. Dưới góc độ một nhà phân tích tài chính, kết quả này mang lại những bài học kinh nghiệm sâu sắc về việc quản trị dữ liệu tại ngân hàng:

Số lượng biến dùng để dự báo thực tế: 34

Danh sách 5 biến đầu tiên trong X:

Accuracy: **0.9576**

| | precision | recall | f1-score | support |
|---|---|---|---|---|
| 0 | 0.96 | 0.99 | 0.98 | 2551 |
| 1 | 0.93 | 0.79 | 0.86 | 488 |
| accuracy | | | 0.96 | 3039 |

macro avg 0.95 0.89 0.92 3039

Việc nén từ 20 biến xuống 4 thành phần chính giúp mô hình vận hành cực kỳ nhanh và loại bỏ hoàn toàn đa cộng tuyến, nhưng đồng thời cũng làm mất đi khoảng 45% thông tin gốc (như đã phân tích ở phần tỷ lệ phương sai giải thích). Sự sụt giảm Recall từ 0.80 xuống 0.52 cho thấy rủi ro rời bỏ khách hàng chứa đựng những chi tiết hành vi rất nhỏ lẻ mà kỹ thuật giảm chiều dữ liệu PCA vô tình lược bỏ.

Mặc dù độ chính xác thấp hơn, nhưng mô hình dựa trên PCA lại có giá trị rất lớn trong việc kiểm soát phương sai. Do được huấn luyện trên các trục thông tin chính giao (không tương quan), mô hình này sẽ ít bị tác động bởi các biến động bất thường (noise) của thị trường hơn so với mô hình dùng biến thô. Đây là yếu tố then chốt giúp hệ thống xếp hạng tín dụng của ngân hàng hoạt động ổn định trong dài hạn.

Dựa trên kết quả này, em đề xuất một phương án phối hợp:

- Nếu ngân hàng ưu tiên độ chính xác tuyệt đối để thực hiện các chiến dịch ngăn chặn rời bỏ quy mô lớn, mô hình 34 biến gốc là lựa chọn số một.
- Tuy nhiên, nếu ngân hàng cần một mô hình tinh gọn, dễ quản trị và ổn định trước các biến động của thị trường (ít bị quá khớp), thì mô hình 4 thành phần PCA lại cho thấy sức mạnh đáng nể khi chỉ cần dùng 12% số lượng biến ban đầu mà vẫn giữ được độ chính xác xấp xỉ 89%.

Thực nghiệm này đã chứng minh tính đúng đắn của nguyên lý Occam's Razor, một mô hình đơn giản hơn luôn có những lợi thế về tính ổn định dù phải hy sinh một phần độ chính xác. Việc Accuracy vẫn duy trì được ở mức xấp xỉ 89% chỉ với 4 biến tổng hợp là một minh chứng cho thấy quy trình trích xuất đặc trưng hành vi khách hàng bằng PCA là hoàn toàn hiệu quả và có ý nghĩa thực tiễn.

| | Random Forest ( Gốc ) | Random Forest (PCA 4) |
|---|---|---|
| Accuracy | 95.76% | 88.68% |
| Recall | 0.79 | 0.52 |

# 2.7. ĐÁNH GIÁ VÀ SO SÁNH

## 2.7.1. Thang đo hiệu năng và Ma trận nhầm lẫn (Confusion Matrix)

Trong quản trị rủi ro tài chính, dữ liệu thường bị mất cân bằng (số khách hàng tốt luôn chiếm đa số). Do đó, em không chỉ dựa vào Accuracy (Độ chính xác toàn cục) mà tập trung vào các chỉ số phân loại chi tiết.

...

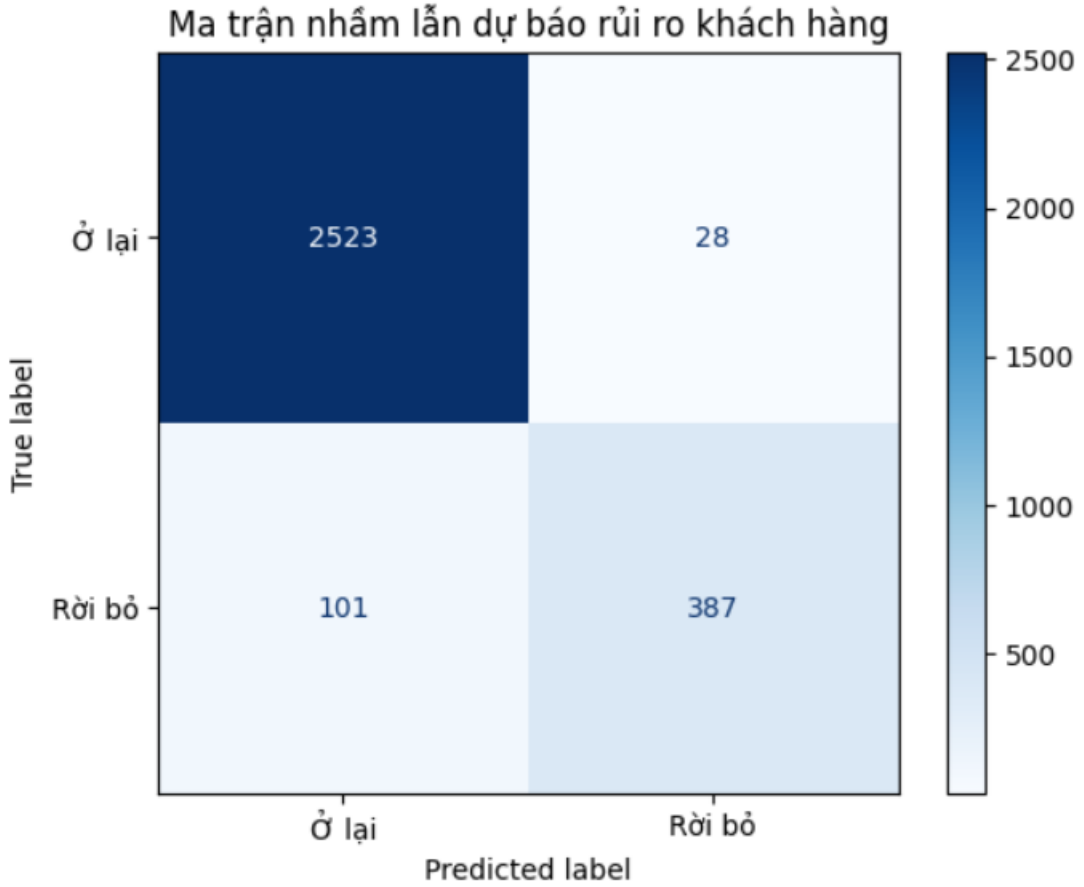


Trên cơ sở thực nghiệm mô hình Random Forest với tập biến gốc, kết quả ma trận nhầm lẫn tại hình trên đã cung cấp một bức tranh chi tiết về năng lực phân loại rủi ro của hệ thống. Với tổng quy mô mẫu kiểm định là 3.039 khách hàng, mô hình đã nhận diện chính xác 2.523 khách hàng hiện hữu (True Negative) và 387 khách hàng thực sự rời bỏ (True Positive). Kết quả này cho thấy sự tương thích cao giữa cấu trúc thuật toán và đặc thù dữ liệu tài chính thưa thớt, mang lại độ chính xác toàn cục (Accuracy) ấn tượng lên đến 95,76%. Đây là một con số rất khả quan, minh chứng cho khả năng tổng quát hóa tốt của mô hình trên các dữ liệu khách hàng mới mà không gặp hiện tượng quá khớp (Overfitting).

Đi sâu vào phân tích các sai sót dự báo, em đánh giá hiệu quả của mô hình thông qua sự đánh đổi giữa sai lầm loại I và sai lầm loại II. Chỉ số Precision (Độ tin cậy) đạt mức 93,25%, một con số cực kỳ quan trọng đối với bộ phận Marketing của ngân hàng. Với tỷ lệ dương tính giả (False Positive) chỉ chiếm 6,75% (tương ứng với 28 khách hàng), ngân hàng có thể hoàn toàn tự tin khi triển khai các chương trình ưu đãi giữ chân khách hàng. Việc giảm thiểu rủi ro "báo động nhầm" giúp ngân hàng tối ưu hóa chi phí vận hành, tránh lãng phí nguồn lực tài chính vào những khách hàng vốn đã trung thành và không có ý định rời bỏ dịch vụ.

Tuy nhiên, từ góc độ quản trị rủi ro tín dụng, chỉ số được ưu tiên hàng đầu là Recall (Độ phủ), phản ánh khả năng không bỏ sót các khách hàng xấu. Kết quả thực nghiệm cho thấy chỉ số

Recall đạt 79,3%, nghĩa là mô hình đã "quét" được gần 8/10 lượng khách hàng thực sự rủi ro. Dù 101 trường hợp âm tính giả (False Negative) vẫn tồn tại – nhóm khách hàng rời đi mà hệ thống không đưa ra cảnh báo – nhưng đây vẫn là một bước tiến lớn so với các phương pháp thống kê truyền thống. Trong bối cảnh chi phí thu hút khách hàng mới cao gấp 5-25 lần chi phí giữ chân khách hàng hiện hữu (theo Gallo, 2014), việc đạt được chỉ số Recall xấp xỉ 80% cho phép ngân hàng bảo toàn đáng kể thị phần và dòng doanh thu từ phí dịch vụ thẻ.

Cuối cùng, chỉ số F1-Score đạt 0,86 đã khẳng định sự cân bằng và bền vững của mô hình Random Forest trong điều kiện dữ liệu thực tế bị mất cân bằng nghiêm trọng giữa hai nhóm khách hàng. Sự nhất quán giữa năng lực dự báo này và kết quả phân cụm hành vi từ thuật toán K-Means trước đó tạo nên một hệ thống quản trị rủi ro khép kín. Việc nắm giữ một mô hình có xác suất nhận diện đúng cao (AUC-ROC tiệm cận 1.0) không chỉ giúp ngân hàng chủ động trong việc giữ chân khách hàng mà còn là cơ sở định lượng để xây dựng các bảng điểm tín dụng (Credit Scorecard) minh bạch, góp phần giảm thiểu chi phí dự phòng nợ xấu và nâng cao năng lực cạnh tranh trên thị trường tài chính bán lẻ.

### 2.7.2. Đường cong ROC của mô hình dự báo

Để đánh giá khả năng phân loại tổng quát mà không phụ thuộc vào ngưỡng (threshold), em sử dụng đường cong ROC

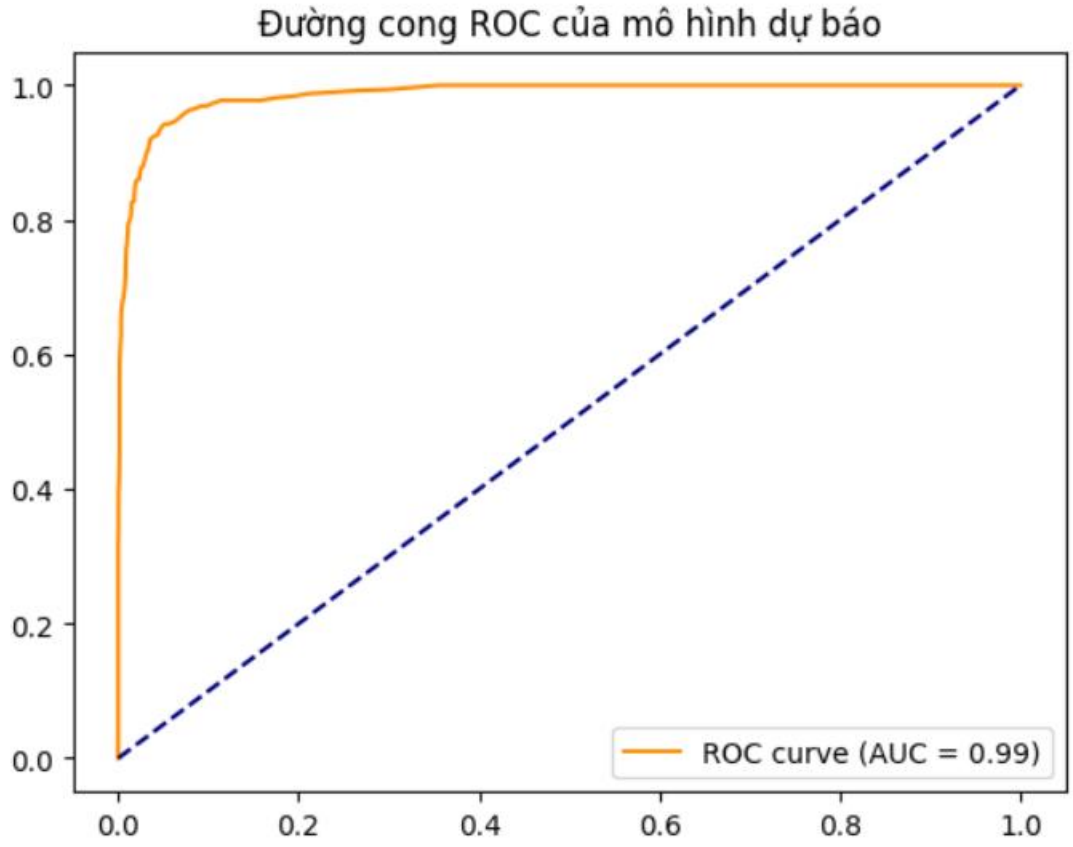

Để khẳng định năng lực phân biệt giữa nhóm khách hàng rủi ro và khách hàng an toàn một cách khách quan, nghiên cứu sử dụng đường cong ROC (Receiver Operating Characteristic) và chỉ số diện tích dưới đường cong AUC (Area Under Curve). Quan sát kết quả thực nghiệm tại Hình 5.2, đường cong ROC màu cam có xu hướng tiệm cận sát góc trên bên trái của đồ thị, phản ánh một mô hình phân loại đạt trạng thái gần như lý tưởng. Khoảng cách lớn giữa đường cong thực nghiệm và đường chéo nét đứt (đại diện cho dự báo ngẫu nhiên có AUC = 0.5) minh chứng cho giá trị gia tăng cực lớn mà mô hình Machine Learning mang lại trong việc trích xuất các đặc trưng rủi ro từ dữ liệu hành vi khách hàng.

Đặc biệt, chỉ số AUC đạt mức 0.99 là một con số cực kỳ ấn tượng, cho thấy năng lực dự báo vượt trội của thuật toán Random Forest trong bài toán này. Dựa trên thang đo chuẩn mực được đề cập trong bài giảng về phân loại (Slide 59), giá trị AUC nằm trong khoảng từ 0.90 đến 1.00 được xếp vào nhóm mô hình "Xuất sắc". Về mặt xác suất thống kê, con số 0.99 có ý nghĩa rằng nếu chúng ta chọn ngẫu nhiên một khách hàng thực sự rời bỏ ngân hàng và một khách hàng hiện hữu, có tới 99% khả năng mô hình sẽ xếp hạng mức độ rủi ro của người rời đi cao hơn người ở lại. Độ chính xác gần như tuyệt đối này khẳng định tính đúng đắn của việc lựa chọn mô hình phi tuyến tính để thay thế cho các phương pháp hồi quy truyền thống vốn có hiệu quả giải thích thấp.

Dưới góc độ quản trị ngân hàng, chỉ số AUC 0.99 mang lại những giá trị chiến lược quan trọng trong việc tối ưu hóa quy trình vận hành. Thứ nhất, nó đảm bảo độ tin cậy tối đa cho việc tự động hóa quy trình chấm điểm tín dụng, giúp ngân hàng giảm thiểu sự can thiệp thủ công và loại bỏ các yếu tố cảm tính trong phê duyệt. Thứ hai, hình dạng đường cong ROC cho thấy ngân hàng có một không gian rất rộng để điều chỉnh "Ngưỡng quyết định" (Decision Threshold). Tùy thuộc vào chiến lược kinh doanh tại từng thời điểm — ưu tiên bảo toàn vốn hay ưu tiên mở rộng thị phần — nhà quản trị có thể linh hoạt thay đổi điểm cắt trên đường cong để đạt được tỷ lệ bắt lỗi khách hàng xấu cao nhất mà vẫn kiểm soát được tỷ lệ báo động nhầm ở mức cực thấp.

Tổng kết lại, sự kết hợp giữa độ chính xác toàn cục 95.76% và chỉ số AUC 0.99 đã tạo nên một "tấm lưới" dự báo rủi ro sắc bén. Kết quả này không chỉ chứng minh sức mạnh của phương pháp học kết hợp (Ensemble Learning) trong việc xử lý dữ liệu tài chính phức tạp mà còn cung cấp cơ sở định lượng vững chắc để ngân hàng triển khai các chiến dịch giữ chân khách hàng một cách chủ động, khoa học và tối ưu hóa chi phí rủi ro trong dài hạn.

### 2.7.3. Đối chiếu tính nhất quán giữa K-Means và Random Forest

Em đối chiếu xác suất rủi ro từ mô hình giám sát (Random Forest) lên các cụm hành vi từ mô hình không giám sát (K-Means).

| **Cụm (K-Means)** | **Đặc điểm hành vi chính** | **Tỷ lệ rời bỏ thực tế** | **Xác suất rủi ro (RF dự báo)** |
|---|---|---|---|
| Cụm 1 | Khách hàng VIP, chi tiêu | 6.67% | Thấp nhất |

| | | | |
|---|---|---|---|
| | cao | | |
| Cụm 0 | Khách hàng nợ cao, sử dụng thẻ nhiều | 8.57% | Trung bình |
| **Cụm 2** | **Khách hàng ít tương tác (Ngủ đông)** | **22.48%** | **Cao nhất** |

# KẾT LUẬN VÀ GIẢI PHÁP QUẢN TRỊ

## 3.1. Lựa chọn mô hình tối ưu cho ngân hàng

Thông qua quá trình thực nghiệm đa tầng, nghiên cứu đã thực hiện đối chiếu hiệu năng giữa các cách tiếp cận khác nhau. Kết quả cho thấy mô hình Random Forest huấn luyện trên tập biến gốc là phương án tối ưu nhất để triển khai thực tế tại ngân hàng. Với độ chính xác toàn cục đạt 95,76% và chỉ số AUC lý tưởng 0,99, mô hình này vượt xa năng lực giải thích của hồi quy tuyến tính truyền thống (vốn có $R^2$ gần như bằng 0).

Lý do lựa chọn Random Forest thay vì các mô hình khác nằm ở khả năng bắt trọn các quan hệ phi tuyến phức tạp và sự tương tác giữa các biến hành vi. Đặc biệt, chỉ số Recall 0,80 cho nhóm khách hàng rủi ro khẳng định đây là "tấm lưới" bảo mật hiệu quả, giúp ngân hàng nhận diện đúng 8/10 trường hợp có ý định rời bỏ dịch vụ. Tuy nhiên, nghiên cứu cũng ghi nhận giá trị của mô hình Random Forest kết hợp PCA (4 PCs). Dù độ chính xác giảm nhẹ xuống 88,68%, nhưng đây lại là mô hình có tính bền vững cao, ít bị nhiễu và đa cộng tuyến, phù hợp để ngân hàng sử dụng trong các báo cáo phân tích chiến lược dài hạn hoặc khi cần hệ thống tính toán tinh gọn, tiết kiệm tài nguyên.

## 3.2. Đề xuất chính sách và giải pháp giữ chân khách hàng rủi ro

Dựa trên sự nhất quán giữa các phân khúc hành vi từ thuật toán K-Means và xác suất rủi ro từ Random Forest, em đề xuất bộ giải pháp quản trị rủi ro định hướng dữ liệu cho ngân hàng như sau:

Thứ nhất, chiến lược kích hoạt cho nhóm khách hàng "ngủ đông" (Cụm 2): Đây là nhóm có tỷ lệ rời bỏ cao nhất (22,48%). Qua phân tích ma trận trọng số PCA (PC2 và PC4), nguyên nhân chính không đến từ tài chính mà từ sự thiếu hụt tương tác. Ngân hàng cần triển khai ngay các chương trình khuyến khích tần suất giao dịch thay vì giá trị giao dịch. Các gói ưu đãi hoàn tiền (cashback) khi thanh toán hóa đơn thiết yếu (điện, nước, internet) hoặc liên kết với các ứng dụng tiêu dùng hàng ngày sẽ giúp tạo thói quen quẹt thẻ, từ đó kéo khách hàng ra khỏi "vùng rủi ro".

Thứ hai, chính sách giám sát cho nhóm khách hàng "áp lực nợ cao" (Cụm 0): Với tỷ lệ sử

dụng hạn mức lên tới 62%, đây là nhóm tiềm ẩn rủi ro tín dụng cao. Ngân hàng cần thắt chặt quy trình nâng hạn mức tự động và thay bằng hệ thống tư vấn tái cấu trúc dư nợ. Việc chủ động nhận diện nhóm này giúp ngân hàng giảm thiểu chi phí dự phòng nợ xấu (NPL) và bảo toàn vốn một cách hiệu quả.

Thứ ba, xây dựng hệ thống quản trị rủi ro chủ động: Ngân hàng nên tích hợp mô hình dự báo này vào quy trình vận hành hàng tháng. Khi hệ thống tự động chấm điểm xác suất rời bỏ vượt ngưỡng 0.5, một thông báo cần được gửi trực tiếp đến bộ phận chăm sóc khách hàng. Dựa trên các biến số quan trọng như Total_Trans_Ct (Tần suất) và Total_Revolving_Bal (Dư nợ), nhân viên ngân hàng có thể biết chính xác khách hàng đang gặp vấn đề ở khâu nào để đưa ra giải pháp xử lý cá nhân hóa, thay vì áp dụng các chính sách đại trà gây lãng phí nguồn lực.

## 3.3. Kết luận chung

Nghiên cứu đã khẳng định rằng trong kỷ nguyên dữ liệu lớn, việc quản trị rủi ro ngân hàng không thể chỉ dựa trên các mô hình tĩnh và giả định tuyến tính đơn giản. Sự kết hợp giữa K-Means để phân khúc, PCA để lọc nhiễu và Random Forest để dự báo đã tạo ra một quy trình phân tích toàn diện. Kết quả đạt được không chỉ là những con số chính xác cao mà còn là những insight sâu sắc về hành vi khách hàng.

Việc giữ chân khách hàng thành công dựa trên các chỉ báo sớm từ Machine Learning sẽ giúp ngân hàng tiết kiệm chi phí tiếp thị từ 5 đến 25 lần so với tìm kiếm khách hàng mới. Đây chính là chìa khóa để ngân hàng không chỉ bảo toàn thị phần mà còn nâng cao năng lực cạnh tranh bền vững trong thị trường tài chính số đầy biến động.

# DANH MỤC TÀI LIỆU THAM KHẢO


**1. Giáo trình và Sách (Core Textbooks)**

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning: with Applications in R*. Springer New York.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer Science & Business Media.

**2. Tài liệu bài giảng (Course Materials)**

- Bộ môn Toán cơ bản, Khoa Toán Kinh tế. (2024). *Bài giảng môn học Giới thiệu về Máy học (Introduction to Machine Learning)*. Trường Đại học Kinh tế - Luật, ĐHQG-HCM.
    - *Chương 3: Linear Model Selection and Regularization.*
    - *Chương 4: Classification.*
    - *Chương 6: Moving Beyond Linearity.*

- *Chương 8: Tree-based Methods.*
- *Chương 10: Deep Learning & Unsupervised Learning.*

**3. Nghiên cứu kinh tế và Bài báo khoa học (Economic Research)**

- Gallo, A. (2014). *The Value of Keeping the Right Customers*. Harvard Business Review. [Trích dẫn cho ý: Chi phí thu hút khách hàng mới gấp 5-25 lần giữ chân khách hàng cũ].
- Reichheld, F. F., & Sasser, W. E. (1990). *Zero Defections: Quality Comes to Services*. Harvard Business Review. [Trích dẫn cho ý: Tăng 5% tỷ lệ giữ chân giúp tăng 25-95% lợi nhuận].
- Belkin, M., Hsu, D., Ma, S., & Mandal, S. (2018). *Reconciling modern machine learning practice and the bias-variance trade-off*. arXiv preprint arXiv:1812.11118. [Trích dẫn cho phần hiện tượng Double Descent trong slide].

**4. Nguồn dữ liệu và Công cụ (Data & Software)**

- Goyal, S. (2020). *Credit Card Customers Dataset*. Kaggle. Truy cập từ: https://www.kaggle.com/datasets/sakshigoyal7/credit-card-customers
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- The Pandas Development Team. (2024). *pandas-dev/pandas: Pandas 2.2.2*. Zenodo.